Trabajo Práctico Número 1

Minería de Datos

Grupo [Número de Grupo]

Tutor: [Nombre del Tutor]

Integrantes:

Nombre y Apellido	Legajo
Lopez, Matias	02670/0
Silicaro Pera, Isidro	03326/9
Pacchialat, Taciano	03358/8

27 de marzo de 2026

1. Medidas descriptivas (media, cuartiles, etc.)

Para una variable $x_1, \ldots, x_n$:

- **Media:** $\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$
- **Mediana:**
  - Ordenar los datos.
  - Si n es impar: posición $\frac{n+1}{2}$
  - Si n es par: promedio entre las posiciones $\frac{n}{2}$ y $\frac{n}{2} + 1$
- **Q1 y Q3:** se calculan sobre datos ordenados (*aclarar el criterio que usan, porque hay varios*).
- **Rango Intercuartílico (RI):** $RI = Q3 - Q1$

Tabla de valores ordenados:

2. Discretización por frecuencia

Los cortes numéricos calculados son: 1,0, 4,5 y 22,0.

	Baja	**Alta**
Intervalos	[1,0, 4,5]	(4,5, 22,0]
Valores	5	5

3. Discretización por rango

Los cortes numéricos calculados son: 0,979, 11,5 y 22,0.

	Baja	**Alta**
Intervalos	(0,979, 11,5]	(11,5, 22,0]
Valores	8	2

4. Correlación lineal (Pearson)

Al calcular la correlación lineal de Pearson entre la Luminosidad y la Temperatura, se obtuvieron los siguientes resultados:

Atributo	**Valor**
Correlación Lineal	0,5878
Intensidad	Débil
Tipo	Positiva

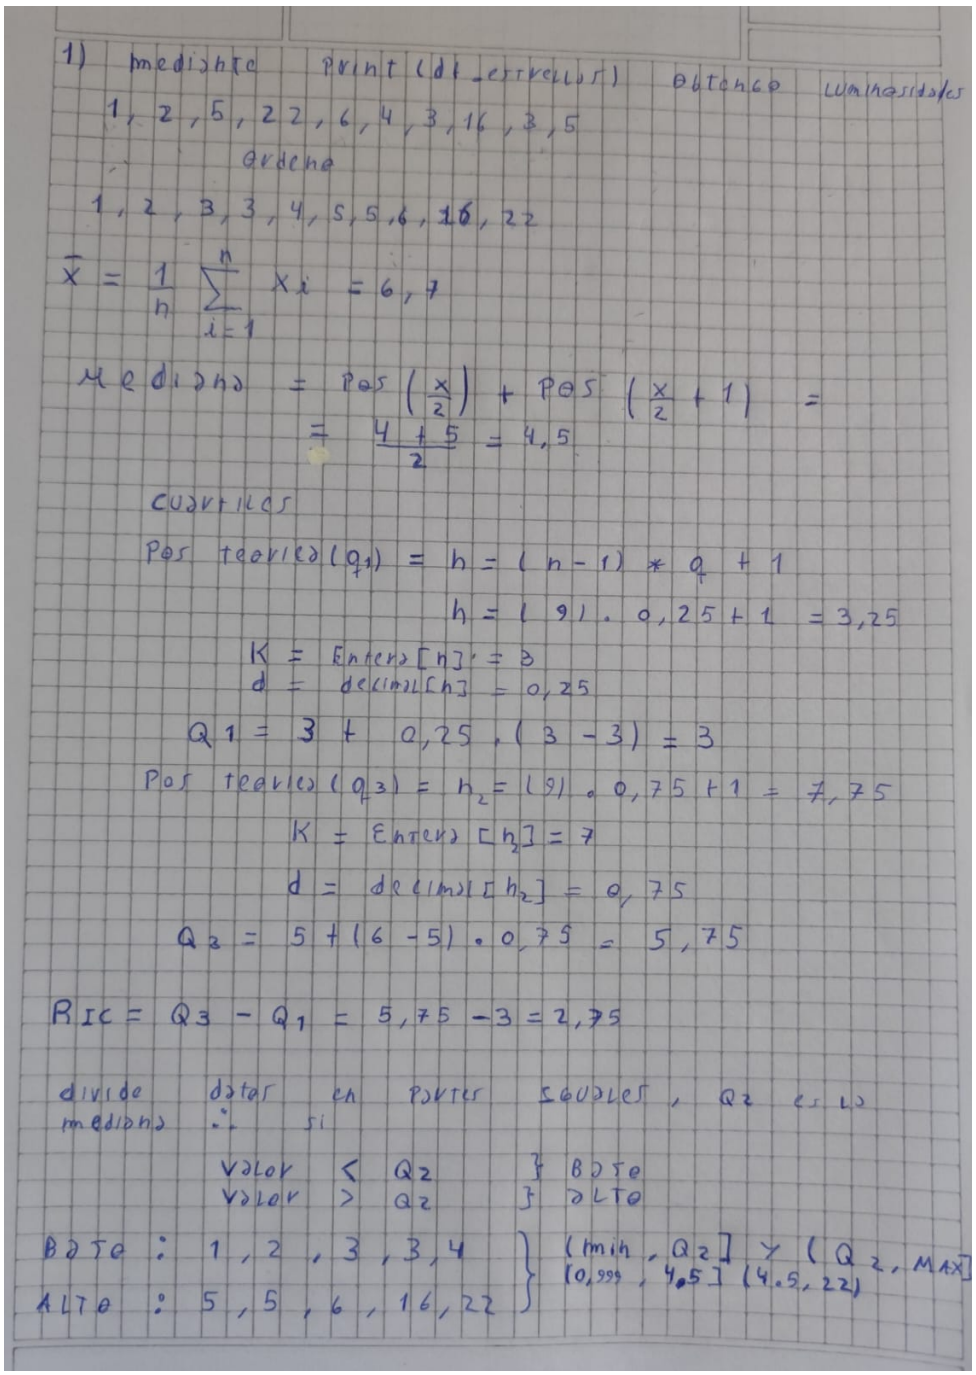


Figura 1: Desarrollo manual de las medidas descriptivas.

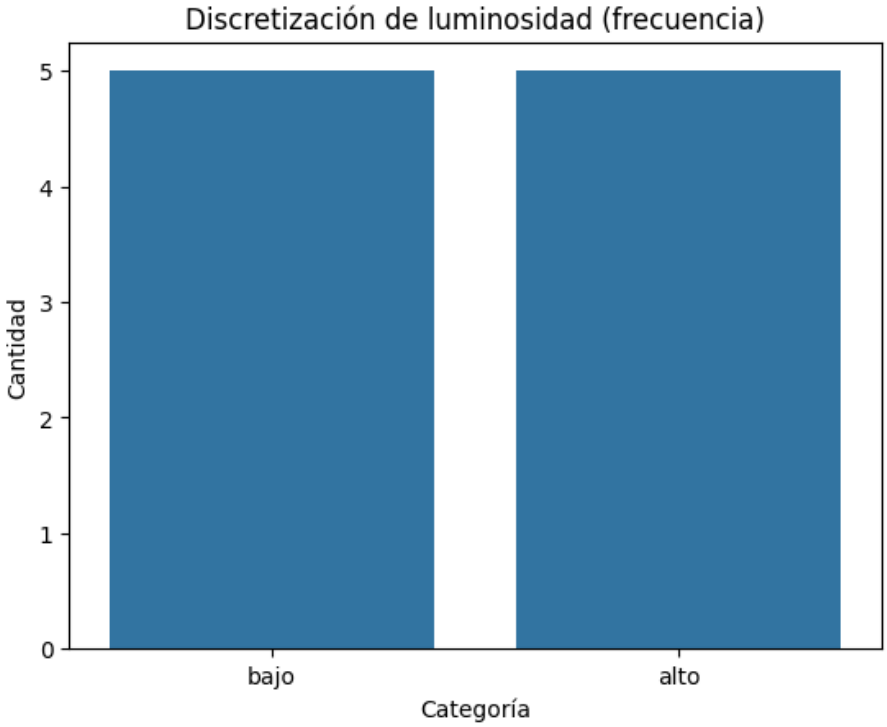


Figura 2: Gráfico de cantidad de estrellas por categoría de luminosidad.

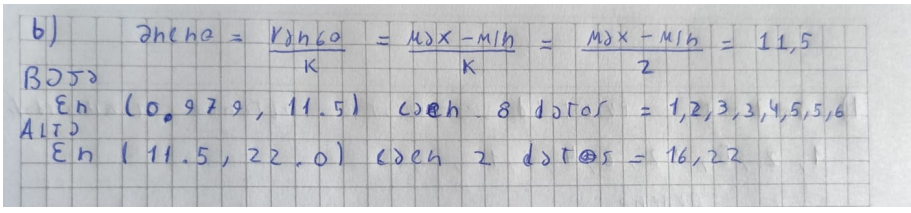


Figura 3: Cálculos manuales de discretización por rango para luminosidad.

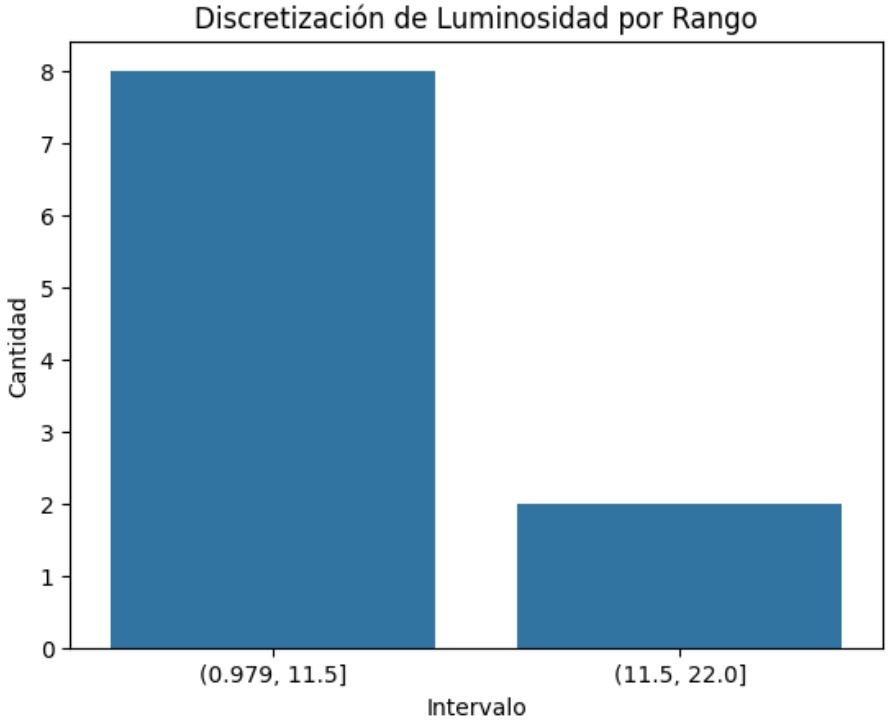


Figura 4: Gráfico de cantidad de estrellas por rango de luminosidad.

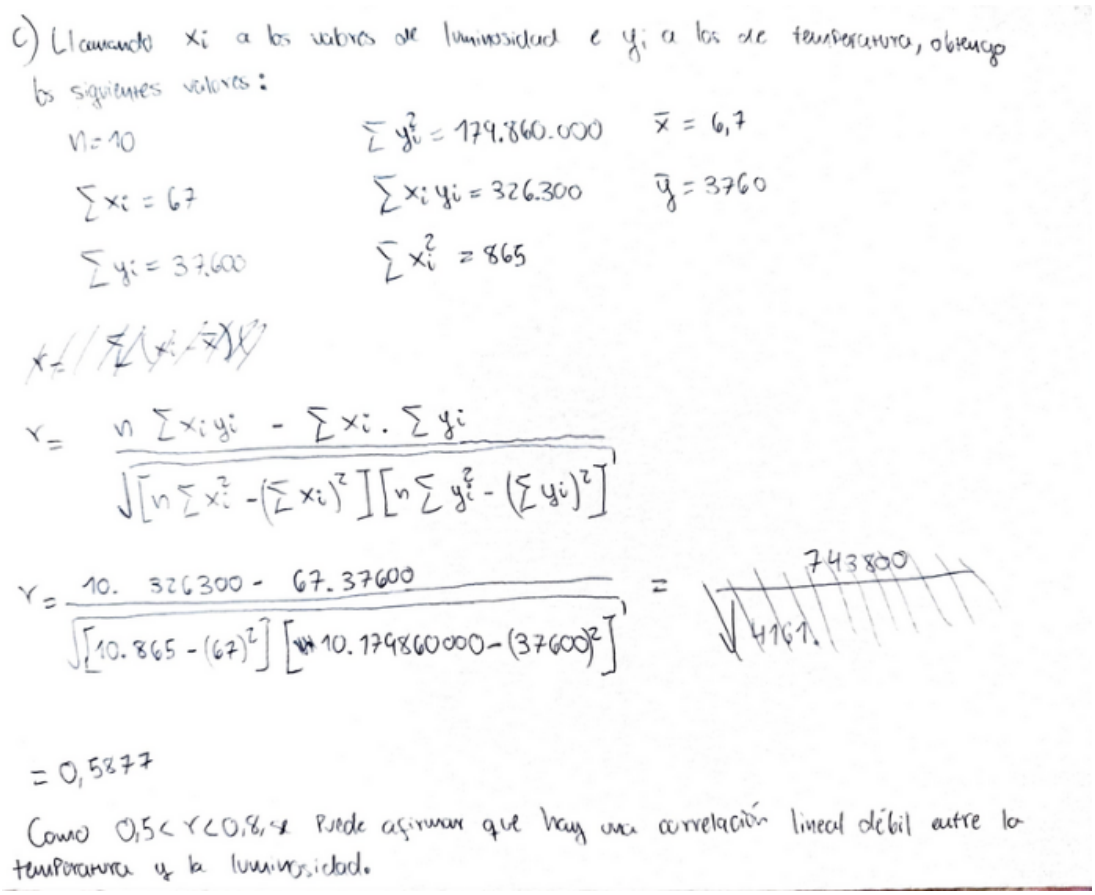


Figura 5: Correlación lineal entre Luminosidad y Temperatura a mano.

Figura 6: Diagrama de dispersión de Luminosidad vs Temperatura.

Como se puede observar, si comparamos el valor obtenido con las librerías de software y el obtenido a mano, podemos hallar una leve discrepancia. Esto se debe a que el valor de la foto fue obtenido mediante calculadora.

5. Diagrama de Caja de Tukey "a mano"

Se calculó el diagrama de caja de Tukey para la variable **Luminosidad**. Los resultados se muestran en la tabla a continuación:

Parámetro	**Valor**
Mediana (Q2)	4,5000
Q1 (Cuartil 1)	3,0000
Q3 (Cuartil 3)	5,7500
RI (Rango Intercuartil)	2,7500
Bigote superior	6
Bigote inferior	1
Intervalo atípicos leves	$[-1{,}1250, 9{,}8750]$
Valores atípicos leves	Ninguno
Intervalo atípicos extremos	$[-5{,}2500, 14{,}0000]$
Valores atípicos extremos	$16, 22$

D) Ordeno los valores de menor a mayor

0	1	2	3	4	5	6	7	8	9
1	2	3	3	4	5	5	6	16	22

Mediana $= \frac{4+5}{2} = 4{,}5$

$Q_1 = 3$, $Q_3 = 6$

$RI = Q_3 - Q_1 = 3$

El bigote inferior lo podemos pensar como el máximo entre el mínimo de luminosidad y $Q_1 - \frac{3}{2} \cdot RI = 3 - \frac{3}{2} \cdot 3 = -1{,}5$. 1 es más grande que $-1{,}5$, entonces el bigote inferior será 1.

El superior es el valor del conjunto mayor o igual a $Q_3 + \frac{3}{2} \cdot RI = 6 + \frac{3}{2} \cdot 3 = 10{,}5$. Este es 6.

Los atípicos leves son los que están por encima de $Q_3 + \frac{3}{2} RI = 10{,}5$ o por debajo de $Q_1 - \frac{3}{2} RI = -1{,}5$.

Los atípicos extremos son mayores a $Q_3 + 3 \cdot RI = 15$ o menores a $Q_1 - 3 \cdot RI = -6$

Los atípicos extremos son 16 y 22.

El intervalo de atípicos leves es $[-6, -1{,}5]$ y $[10{,}5, 15]$.

El de extremos es $(-\infty, -6)$ y $(15, \infty)$.

Figura 7: Cálculos y dibujo manual del Diagrama de Caja de Tukey para Luminosidad.

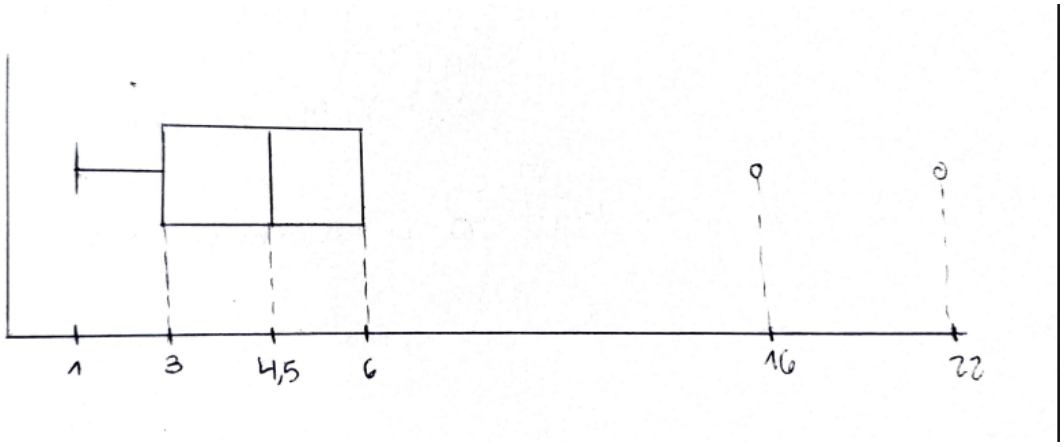


Figura 8: Dibujo manual del Diagrama de Caja de Tukey para Luminosidad.

La diferencia entre los valores de los cuartiles calculados de forma manual y los obtenidos mediante las herramientas de Python radica en que, cuando se lleva a cabo manualmente, se realiza con el método original. Por otro lado, al hacerlo con Python las librerías automáticamente realizan una interpolación entre las muestras, causando que el cuartil 3 (y todos los valores derivados del cuartil 3) se vean modificados levemente.