Minería de Datos usando Sistemas Inteligentes



Trabajo Práctico 2

Clustering

Grupo: 1

Tutor: Oscar Agustín Stanchi

Integrantes:

- Lopez, Matias 02670/0
- Silicaro Pera, Isidro 03326/9
- Pacchialat, Taciano 03358/8



2. Algoritmo K-medias

Inciso A

En la siguiente figura se ilustran las posiciones iniciales de los datos (x_1, x_2, x_3, x_4) y los centroides (c_1, c_2) en el plano X-Y.

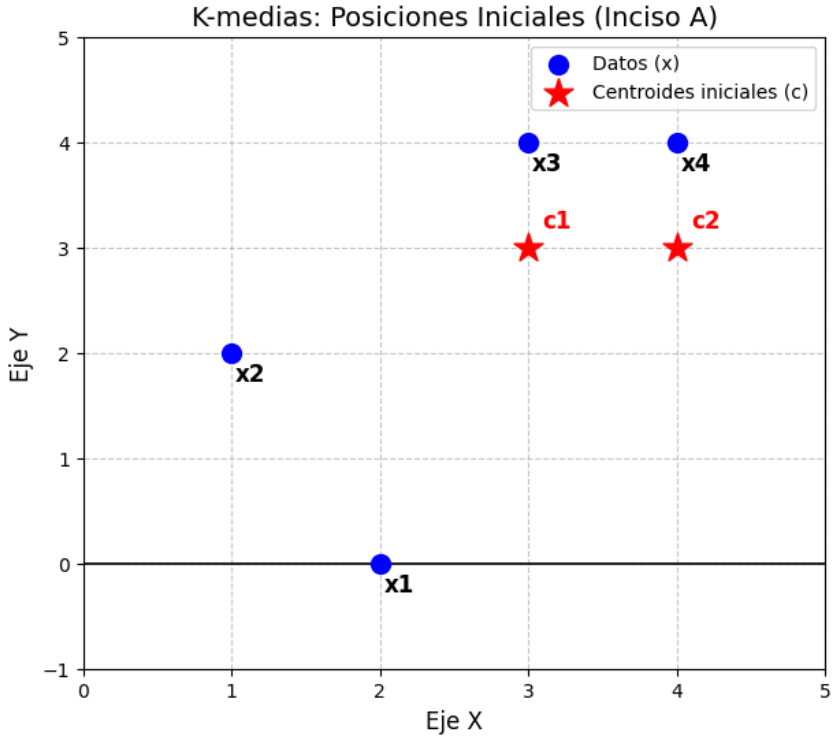


Figura 1: Posiciones iniciales de datos y centroides.

Inciso B

A continuación, se presenta la tabla con los resultados finales tras realizar tres iteraciones del algoritmo K-medias con $k = 2$, utilizando la distancia euclídea al cuadrado.

Puntos	Dist a c1	Dist a c2	Centroide	Dist a c1	Dist a c2	Centroide	Dist a c1	Dist a c2	Centroide
.	Iteración 1	.	.	Iteración 2	.	.	Iteración 3	.	.
x1 = (2,0)	10	13	c1	4	20	c1	1.25	18.25	c1
x2 = (1,2)	5	10	c1	1	13	c1	1.25	10.25	c1
x3 = (3,4)	1	2	c1	5	1	c2	11.25	0.25	c2
x4 = (4,4)	2	1	c2	8	0	c2	15.25	0.25	c2
Nuevos Centros	c1: (2, 2)	c2: (4, 4)		c1: (1.5, 1)	c2: (3.5, 4)		c1: (1.5, 1)	c2: (3.5, 4)	

Figura 2: Tabla de resultados de las iteraciones de K-medias.

Inciso C

El algoritmo de K-medias funciona de la siguiente manera: se asigna cada punto al centro más cercano y luego se recalculan los centros como el promedio de los puntos asignados. De suceder

que en una iteración las asignaciones no cambian, entonces los promedios tampoco cambian. A este punto se repetirá el cálculo con los mismos centroides, por lo que en la siguiente iteración las distancias vuelven a ser las mismas, por lo que las asignaciones también permanecen iguales. En los siguientes gráficos puede interpretarse gráficamente por qué no habrán cambios.

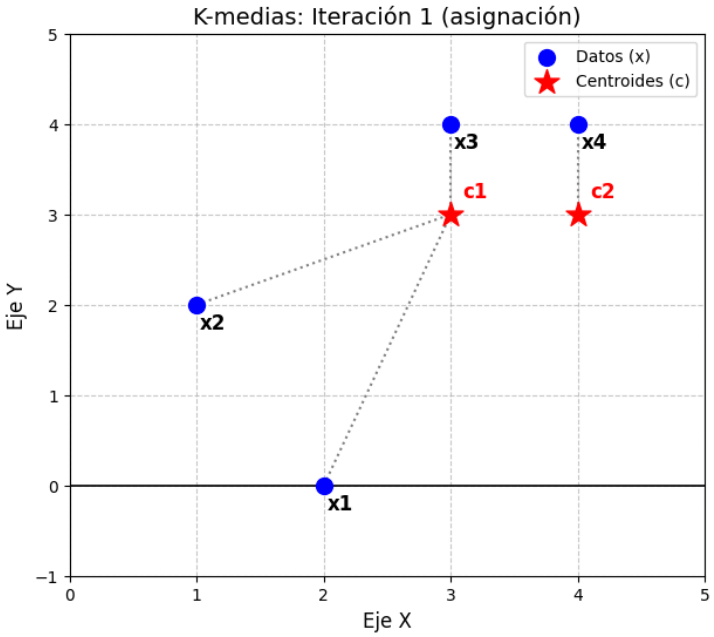


Figura 3: Primera iteración del K-medias.

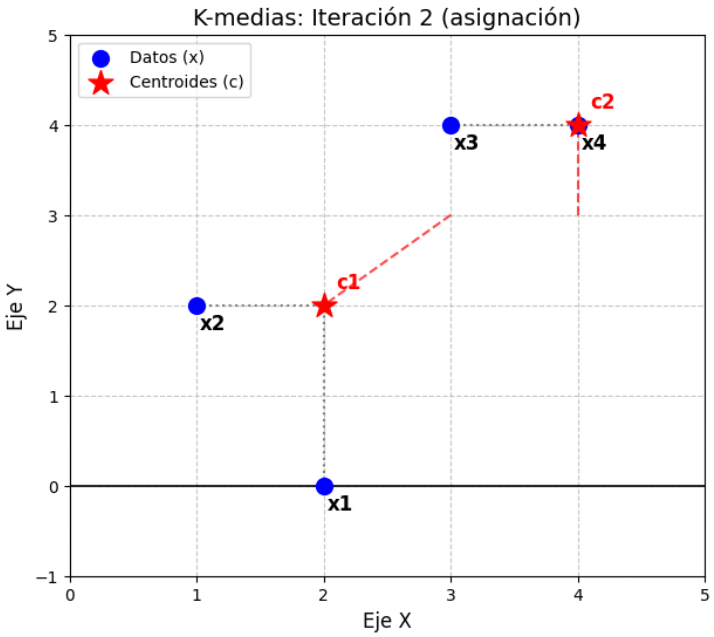


Figura 4: Segunda iteración del K-medias.

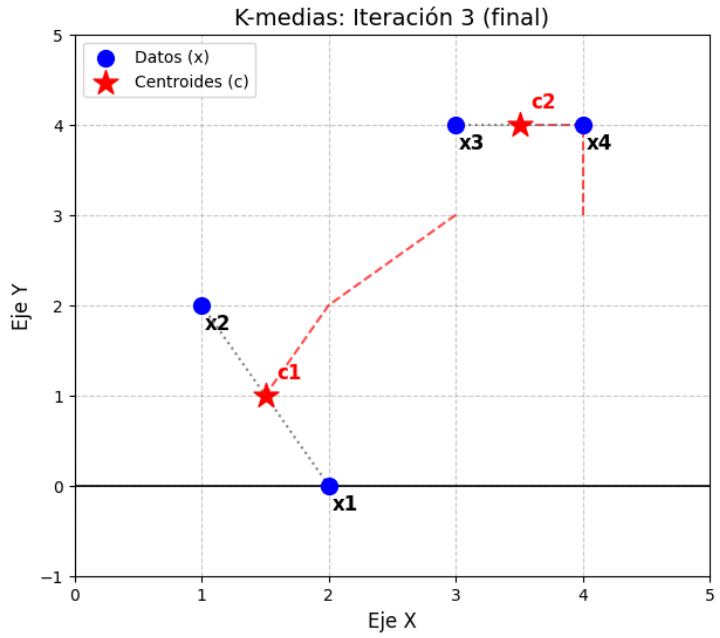


Figura 5: Tercera iteración del K-medias.

En este caso, el resultado final además hace que cada centroide quede a igual distancia de sus dos puntos, porque es el punto medio entre ellos. De manera que es más fácil observar por qué el algoritmo converge y no cambia en siguientes iteraciones.

Inciso D

La tabla con los resultados finales tras realizar tres iteraciones del algoritmo K-medias con los nuevos centroides (c_1, c_2).

Puntos	Dist a c1	Dist a c2	Centroide	Dist a c1	Dist a c2	Centroide	Dist a c1	Dist a c2	Centroide
.	**Iteración 1**	.	.	**Iteración 2**	.	.	**Iteración 3**	.	.
x1 = (2,0)	5	17	c1	1,25	18,25	c1	1,25	18,25	c1
x2 = (1,2)	0	8	c1	1,25	10,25	c1	1,25	10,25	c1
x3 = (3,4)	8	0	c2	11,25	0,25	c2	11,25	0,25	c2
x4 = (4,4)	13	1	c2	15,25	0,25	c2	15,25	0,25	c2
Nuevos Centros	**c1: (1.5, 1)**	**c2: (3.5, 4)**		**c1: (1.5, 1)**	**c2: (3.5, 4)**		**c1: (1.5, 1)**	**c2: (3.5, 4)**	

Figura 6: Tabla de resultados de las iteraciones de K-medias con centroides cambiados.

Inciso E

Se muestra a continuación el movimiento de los centroides cuando sus posiciones iniciales son las siguientes:

$$c_1 = (2, 3), c_2 = (2, -1)$$

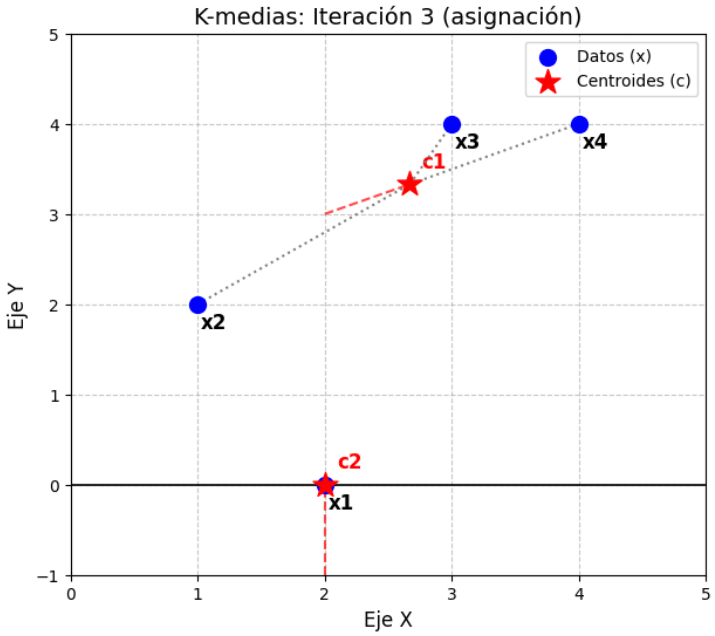


Figura 7: Plot de centroides y puntos con las nuevas coordenadas iniciales.

Y ahora se muestra la tabla de resultados:

Puntos	**Iteración 1**			**Iteración 2**			**Iteración 3**		
	Dist a c_1	Dist a c_2	Centroide	Dist a c_1	Dist a c_2	Centroide	Dist a c_1	Dist a c_2	Centroide
$x_1 = (2, 0)$	9.00	1.00	c_2	11.56	0.00	c_2	11.56	0.00	c_2
$x_2 = (1, 2)$	2.00	10.00	c_1	4.56	5.00	c_1	4.56	5.00	c_1
$x_3 = (3, 4)$	2.00	26.00	c_1	0.56	17.00	c_1	0.56	17.00	c_1
$x_4 = (4, 4)$	5.00	29.00	c_1	2.22	20.00	c_1	2.22	20.00	c_1
Nuevos Centros	c_1 : (2,67, 3,33)	c_2 : (2,00, 0,00)		c_1 : (2,67, 3,33)	c_2 : (2,00, 0,00)		c_1 : (2,67, 3,33)	c_2 : (2,00, 0,00)	

Cuadro 1: Resultados del inciso E tabulados.

Inciso F

Si modificamos el algoritmo K-Medias con un $k = 4$ en un conjunto de datos fijo y se varían los valores de los centroides iniciales, las características que se verán modificadas serán los valores finales de los centroides y la cantidad de ejemplos por centroide. Esto es debido a que el valor de k representa la cantidad de centroides y por ende la cantidad de grupos a formar, por lo que esa cantidad permanece fija. La elección de los centroides iniciales puede modificar la cantidad de iteraciones necesarias para que converja, así como sus valores finales y la cantidad de ejemplos por grupo. Esta conclusión la obtenemos mediante la realización del presente ejercicio 2.

Anexo: Cálculos de cada inciso

En las siguientes imágenes se adjuntan los cálculos desarrollados a mano correspondientes a las asignaciones de distancias y actualización de centroides para cada iteración.

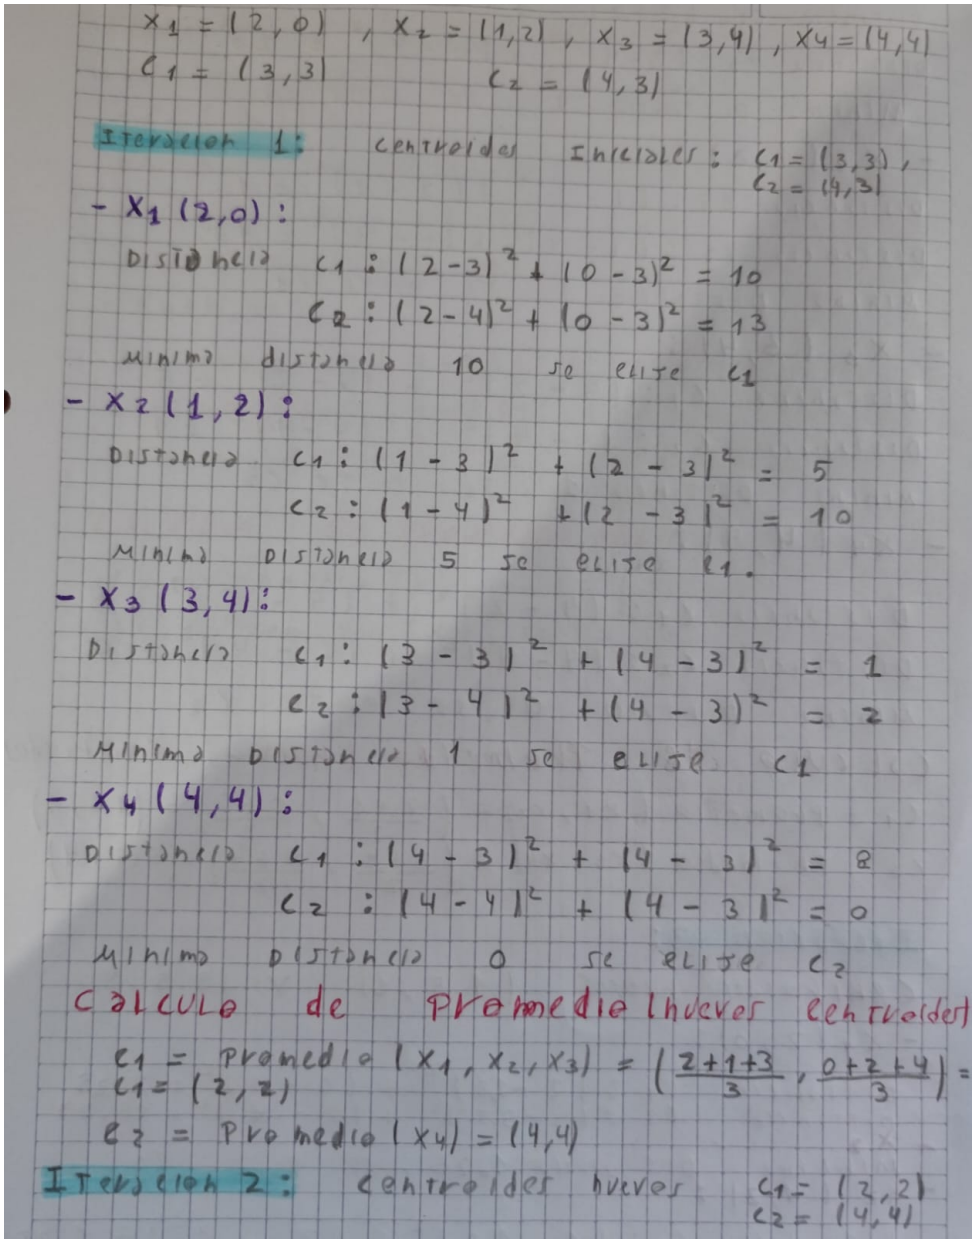


Figura 8: Cálculos a mano - Parte 1.

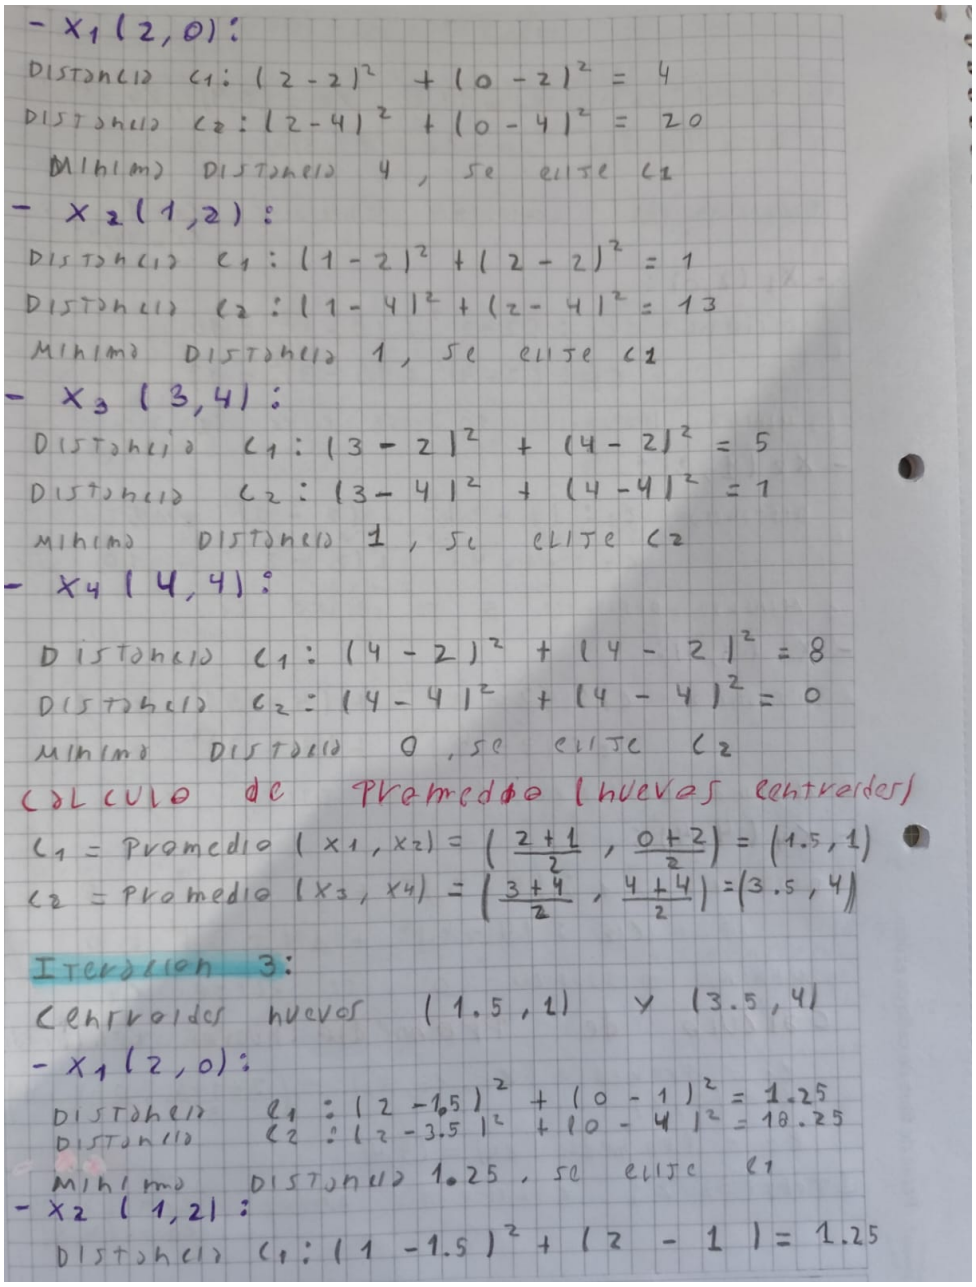


Figura 9: Cálculos a mano - Parte 2.

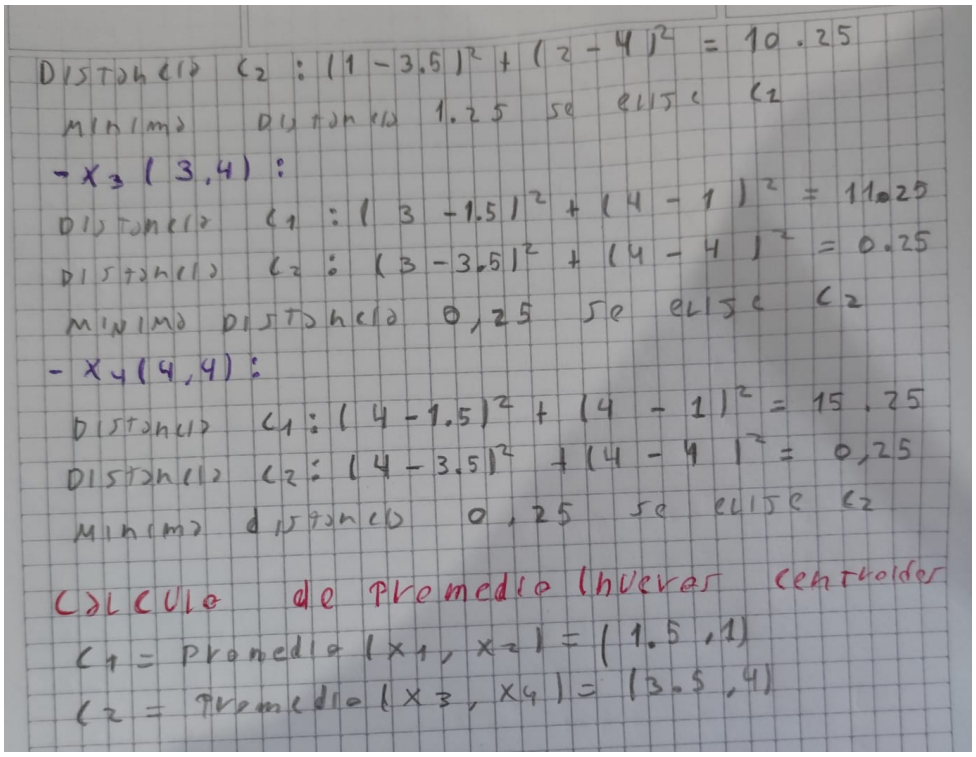


Figura 10: Cálculos a mano - Parte 3.

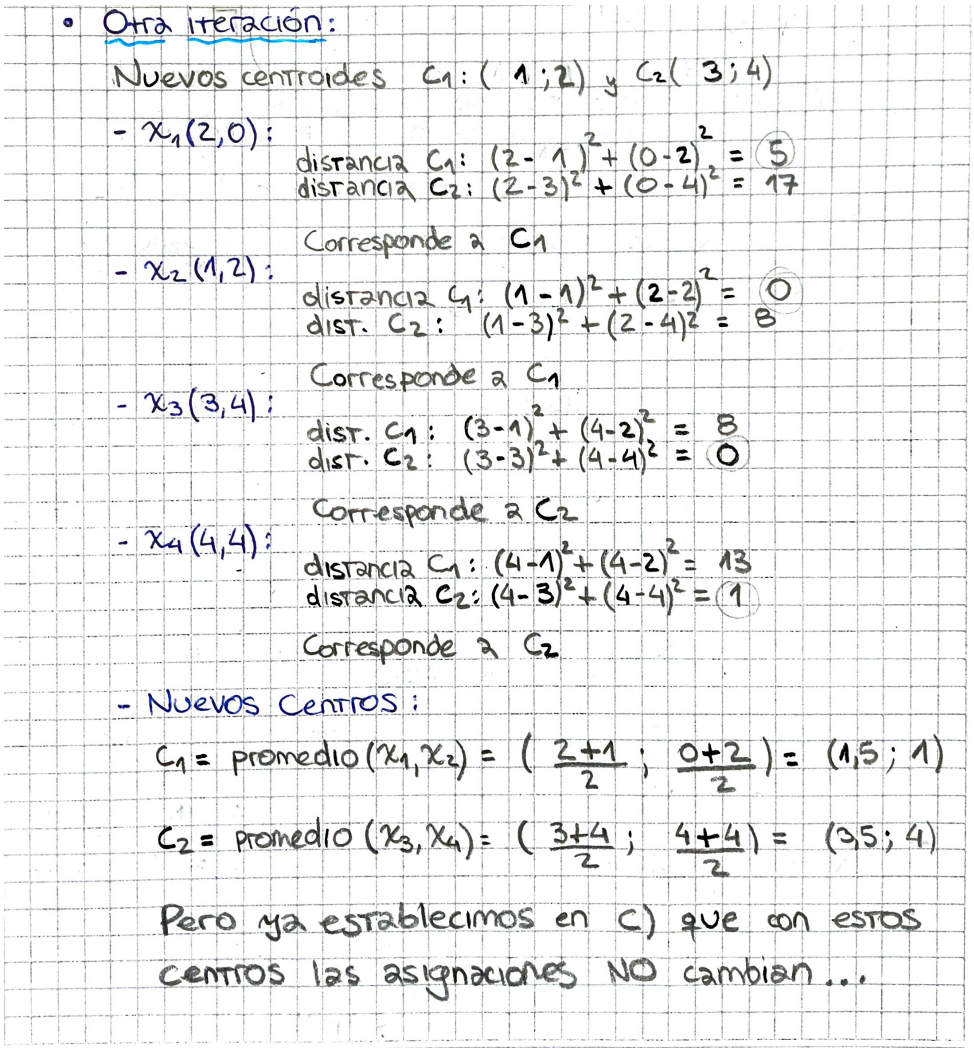


Figura 11: Cálculos a mano - Parte 4.

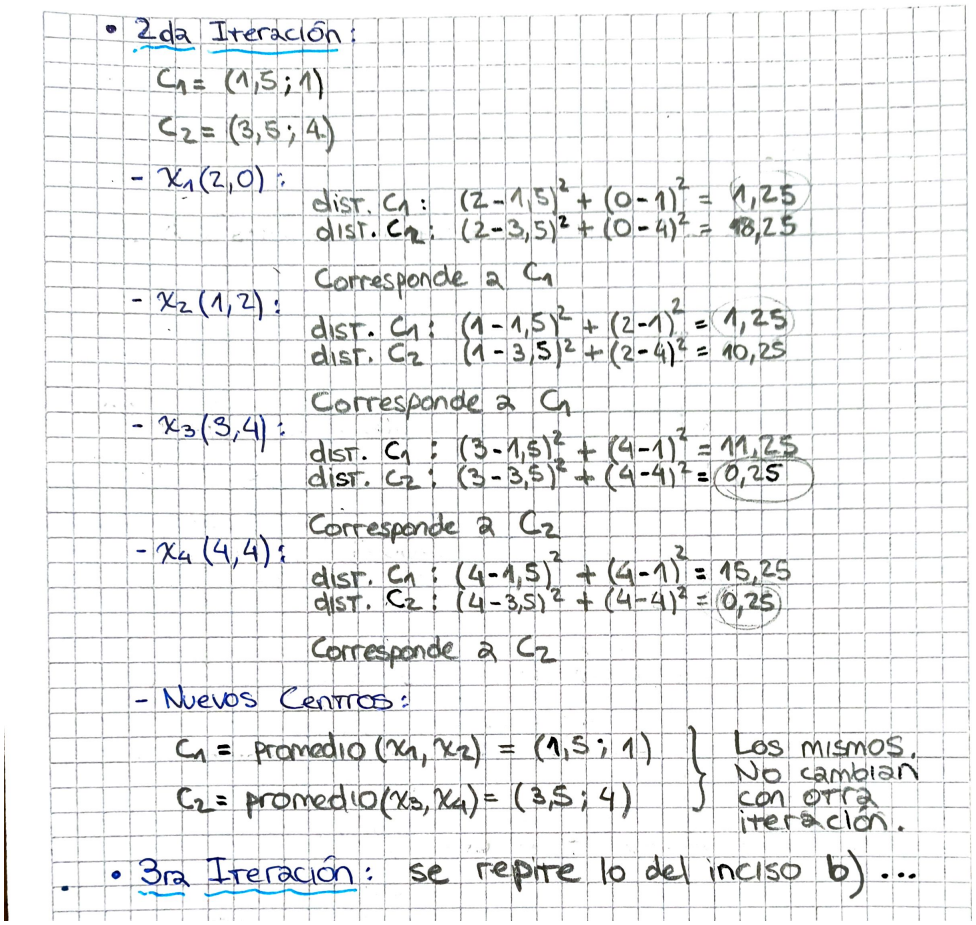


Figura 12: Cálculos a mano - Parte 5.

$X_1 = (2,0)$, $X_2 = (1,2)$, $X_3 = (3,4)$, $X_4 = (4,4)$
$C_1 = (2,3)$, $C_2 = (2,-1)$

Primera Iteración

- $X_1\ (2,0)$:

  $C_1 \rightarrow \sqrt{(2-2)^2 + (0-3)^2} = \sqrt{9} = 3$

  $C_2 \rightarrow \sqrt{(2-2)^2 + (0+1)^2} = 1 \rightarrow$ elige C_2

- $X_2\ (1,2)$:

  $C_1 \rightarrow \sqrt{(1-2)^2 + (2-3)^2} = \sqrt{2} \approx 1{,}41 \rightarrow$ elige C_1

  $C_2 \rightarrow \sqrt{(1-2)^2 + (2+1)^2} = \sqrt{10}$

- $X_3\ (3,4)$:

  $C_1 \rightarrow \sqrt{(3-2)^2 + (4-3)^2} = \sqrt{2} \rightarrow$ elige C_1

  $C_2 \rightarrow \sqrt{(3-2)^2 + (4+1)^2} = \sqrt{26}$

- $X_4\ (4,4)$

  $C_1 \rightarrow \sqrt{(4-2)^2 + (4-3)^2} = \sqrt{5} \rightarrow$ elige C_1

  $C_2 \rightarrow \sqrt{(4-2)^2 + (4+1)^2} = \sqrt{29}$

Nuevos centroides: → Promedio (X_2, X_3, X_4)

$C_1 = \left(\frac{1+3+4}{3}, \frac{2+4+4}{3}\right) \rightarrow C_1 = (2{,}66,\ 3{,}33)$

$C_2 = X_1 = (2,0)$

↳ Promedio $(X_1) = X_1$

Figura 13: Inciso E - Cálculos a mano - Parte 6.

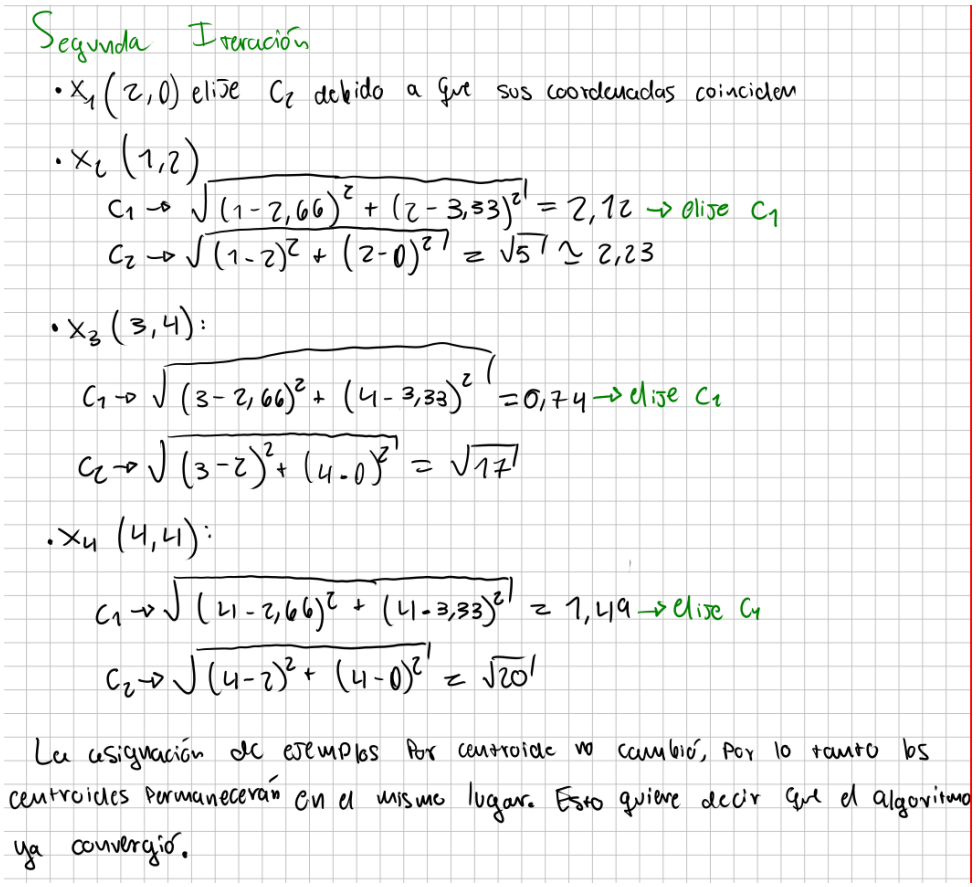


Figura 14: Inciso E - Cálculos a mano - Parte 7.