Minería de Datos usando Sistemas Inteligentes



Trabajo Práctico 3

Naive Bayes

Grupo: 1

Tutor: Oscar Agustín Stanchi

Integrantes:

- Lopez, Matias 02670/0
- Silicaro Pera, Isidro 03326/9
- Pacchialat, Taciano 03358/8



4. Aplicación de un modelo Naive Bayes

Para la resolución de este ejercicio se aplicó el modelo Naïve Bayes considerando el atributo *Color* como discreto y el atributo *Esfericidad* como continuo, asumiendo que este último sigue una distribución Normal.

Los cálculos detallados de las densidades de probabilidad y los productos de verosimilitud correspondientes a cada clase fueron desarrollados de forma manuscrita. Los mismos pueden consultarse de forma detallada en el **Anexo: Procedimientos Manuscritos** al final de este documento.

a) Clases Equiprobables: P(Pera) = 0.5 y P(Manzana) = 0.5

Tras aplicar el teorema de Bayes y la hipótesis MAP sobre los ejemplos dados, se obtuvieron los siguientes resultados:

Color	Esfericidad	P(x — Pera)	P(x — Manzana)	P(x—Pera)*P(P)	P(x—Manz)*P(M)	Predicción
Amarillo	0.6	0.12098	1.00632	0.06049	0.50316	**Manzana**
Mezcla	0.8	1.19682	0.00000	0.59841	0.00000	**Pera**

Tabla 1: Resultados obtenidos con probabilidades a priori equiprobables.

b) Clases NO Equiprobables: P(Manzana) = 0.01 y P(Pera) = 0.99

En este escenario, se observa cómo la probabilidad a priori de la clase Pera tiene un peso determinante en la clasificación final, incluso cuando los atributos individuales presentan una mayor verosimilitud para la clase Manzana.

Color	Esfericidad	P(x — Pera)	P(x — Manzana)	P(x—Pera)*P(P)	P(x—Manz)*P(M)	Predicción
Amarillo	0.6	0.12098	1.00632	0.11977	0.01006	**Pera**
Mezcla	0.8	1.19682	0.00000	1.18485	0.00000	**Pera**

Tabla 2: Resultados obtenidos con sesgo en las probabilidades a priori.

5. Modelo de Naive Bayes

a) Desarrollo del Modelo

El modelo que buscamos desarrollar se basa en el Teorema de Bayes:

$$P(c \mid X) = \frac{P(X \mid c) \cdot P(c)}{P(X)}$$

Dado que $P(X)$ es constante para todas las clases, esta se cancelará en los cálculos, por lo que se utiliza la proporcionalidad:

$$P(c \mid X) \propto P(X \mid c) \cdot P(c)$$

Hay una consideración para tener en cuenta y es que estaremos usando el enfoque Naive Bayes. Se le llama "naive"porque estaremos tomando el Teorema de Bayes y asumiendo independencia condicional entre los atributos. Esto no es necesariamente realista (por ejemplo, podría plantearse que existe una relación entre la Luminosidad y la Temperatura de una estrella), pero asumirlo simplifica enormemente los cálculos.

$$P(X \mid c) = \prod_i P(x_i \mid c)$$

Por lo tanto:

$$P(c \mid X) \propto P(c) \cdot P(T \mid c) \cdot P(L \mid c) \cdot P(H \mid c)$$

5.1 Probabilidades empiricas

Estas no nacen de algún calculo complejo, son simplemente la frecuencia natural con la que se presentan los casos del set de datos.

$$P(K) = 0{,}6 \quad ; \quad P(F) = 0{,}4$$

5.2 Modelado de Variables

a) Variables Continuas

$$P(x \mid c) = \frac{1}{\sqrt{2\pi}\sigma_c} \exp\left(-\frac{(x-\mu_c)^2}{2\sigma_c^2}\right)$$

Estamos tratando con un atributo continuo, de modo que nuestro clasificador NB debe suponer que dicho atributo sigue una distribución normal. De esto se deriva un inconveniente: los datos no siempre siguen una distribución normal; pero bastará para establecer un modelo.

b) Variable Categórica

$$P(H = h \mid c) = \frac{n(H = h, c)}{n(c)}$$

Esta técnica se conoce como estimación por máxima verosimilitud. Debido a que estamos trabajando con pocos registros, el estimador de Laplace resultaría más adecuado. Sin embargo, enunciado mediante, omitiremos el uso del mismo.

5.3 Tabla de Resultados

Atributo / Valor	**Clase F**	**Clase K**
Temperatura μ	5100	2866.67
Temperatura σ	2409.7	1348.58
Habitable = Si	0.25	0.50
Habitable = No	0.75	0.50
Luminosidad μ	11.75	3.33
Luminosidad σ	8.80	1.63

Tabla 3: Parámetros por atributo y clase

Clase	**Probabilidad**
P(Clase F)	0.40
P(Clase K)	0.60

Tabla 4: Probabilidades a priori de clase

b) Procesamiento de Ejemplos

Temp	Habitable	Lum	$P(x\|F)$	$P(x\|K)$	$P(x\|F)P(F)$	$P(x\|K)P(K)$	Pred
1900	No	1	1.11e-6	1.01e-5	4.42e-7	6.04e-6	K
2300	No	2	1.55e-6	2.37e-5	6.21e-7	1.42e-5	K
5500	No	5	4.14e-6	3.19e-6	1.65e-6	1.91e-6	K

Tabla 5: Clasificación de los tres primeros ejemplos (varianza muestral)

c) Comparación entre Dataset y Modelo

Al extender la predicción al resto del conjunto de datos utilizando Python, se obtuvo:

$$\text{accuracy}_{\text{original}} = 0{,}80$$

Esto implica que el modelo clasifica correctamente el 80 % de los ejemplos del dataset original. Por lo tanto, las predicciones no coinciden completamente con las etiquetas reales.

d) Reentrenamiento agregando un nuevo ejemplo

Se agregó el registro:

$$(\text{Temperatura} = 20000,\ \text{Habitable} = \text{No},\ \text{Luminosidad} = 35,\ \text{Clase} = K)$$

Al reentrenar el modelo NB con varianza muestral, se observaron estos cambios:

- Cambian las probabilidades a priori: $P(K)$ pasa de 0,60 a 0,6364 y $P(F)$ de 0,40 a 0,3636.
- La clase K cambia fuertemente en atributos continuos (suben su media y su varianza, especialmente en Temperatura y Luminosidad), porque el nuevo ejemplo es extremo respecto a los anteriores.
- La clase F mantiene sus parámetros de media y varianza, ya que no recibió ejemplos nuevos.

En resumen, el impacto principal del nuevo dato cae sobre la clase K y sobre los priors del modelo.

e) Nuevo accuracy y cambio de predicción

Con el modelo reentrenado del inciso d), el nuevo resultado fue:

$$\text{accuracy}_{\text{nuevo}} = 0{,}7273$$

El accuracy cambió (disminuyó de 0,80 a 0,7273). Además, cambió la predicción de un ejemplo del conjunto original; el ejemplo con índice 2 antes se predecía K, y luego se predijo F, y su etiqueta real es K.

Esto ocurre porque el nuevo ejemplo extremo modifica la distribución estimada de la clase K y cambia los productos utilizados por Naive Bayes.

Anexo: Procedimientos Manuscritos

A continuación se adjuntan las capturas de los procedimientos y cálculos analíticos realizados manualmente para la resolución del Ejercicio 4.

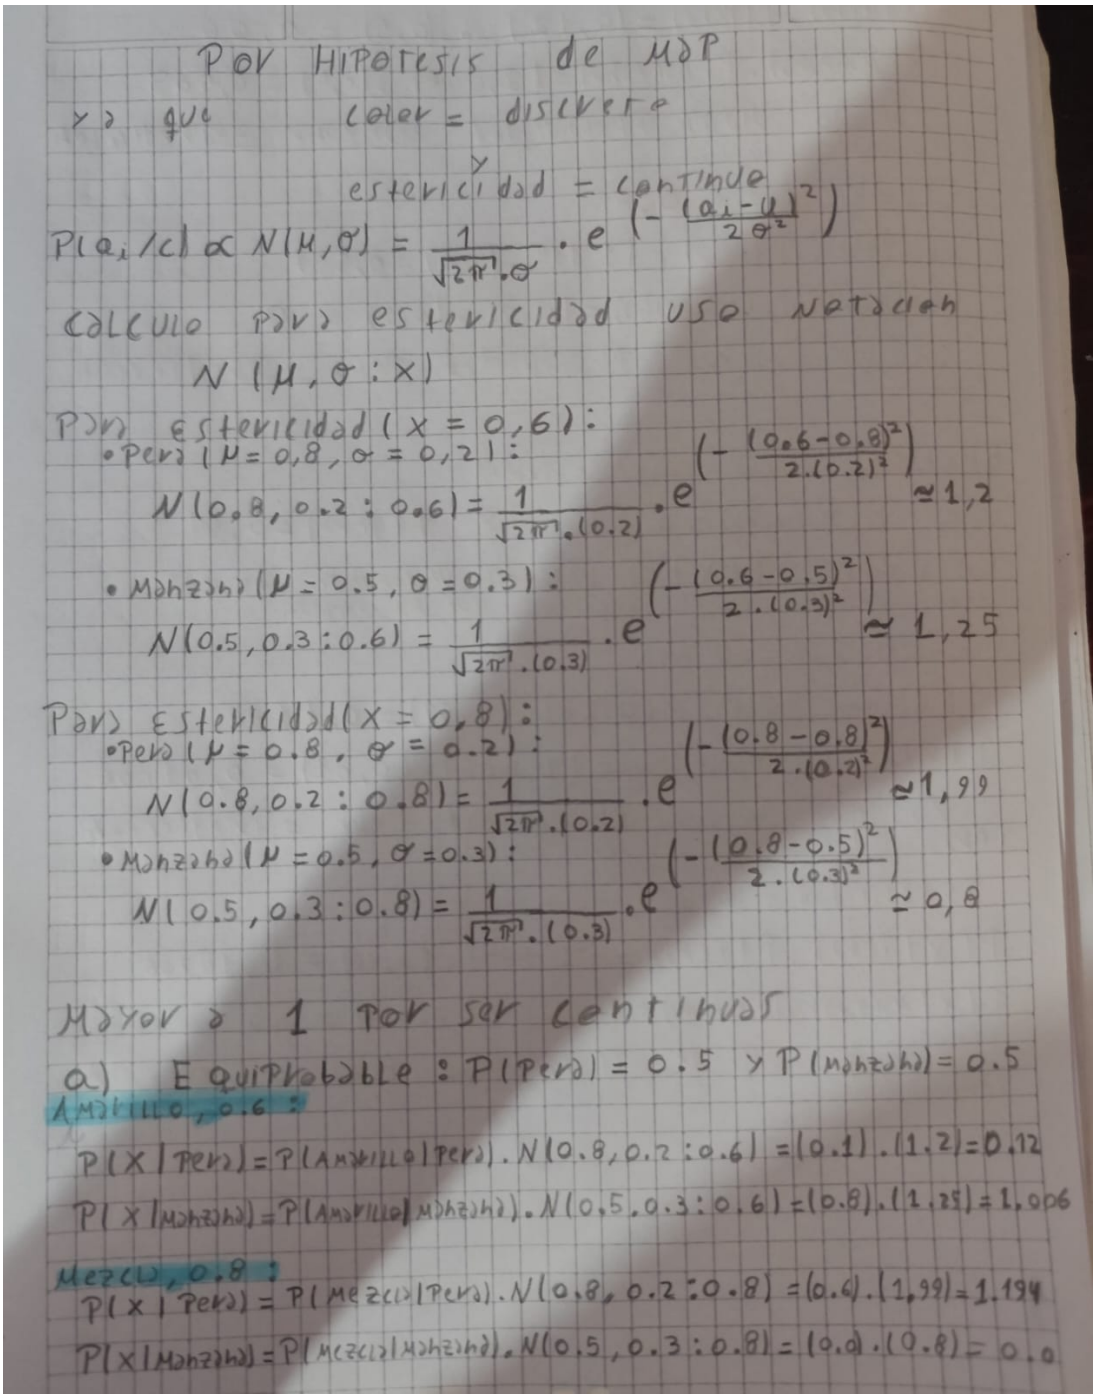


Figura 1: Desarrollo manuscrito del Inciso A.

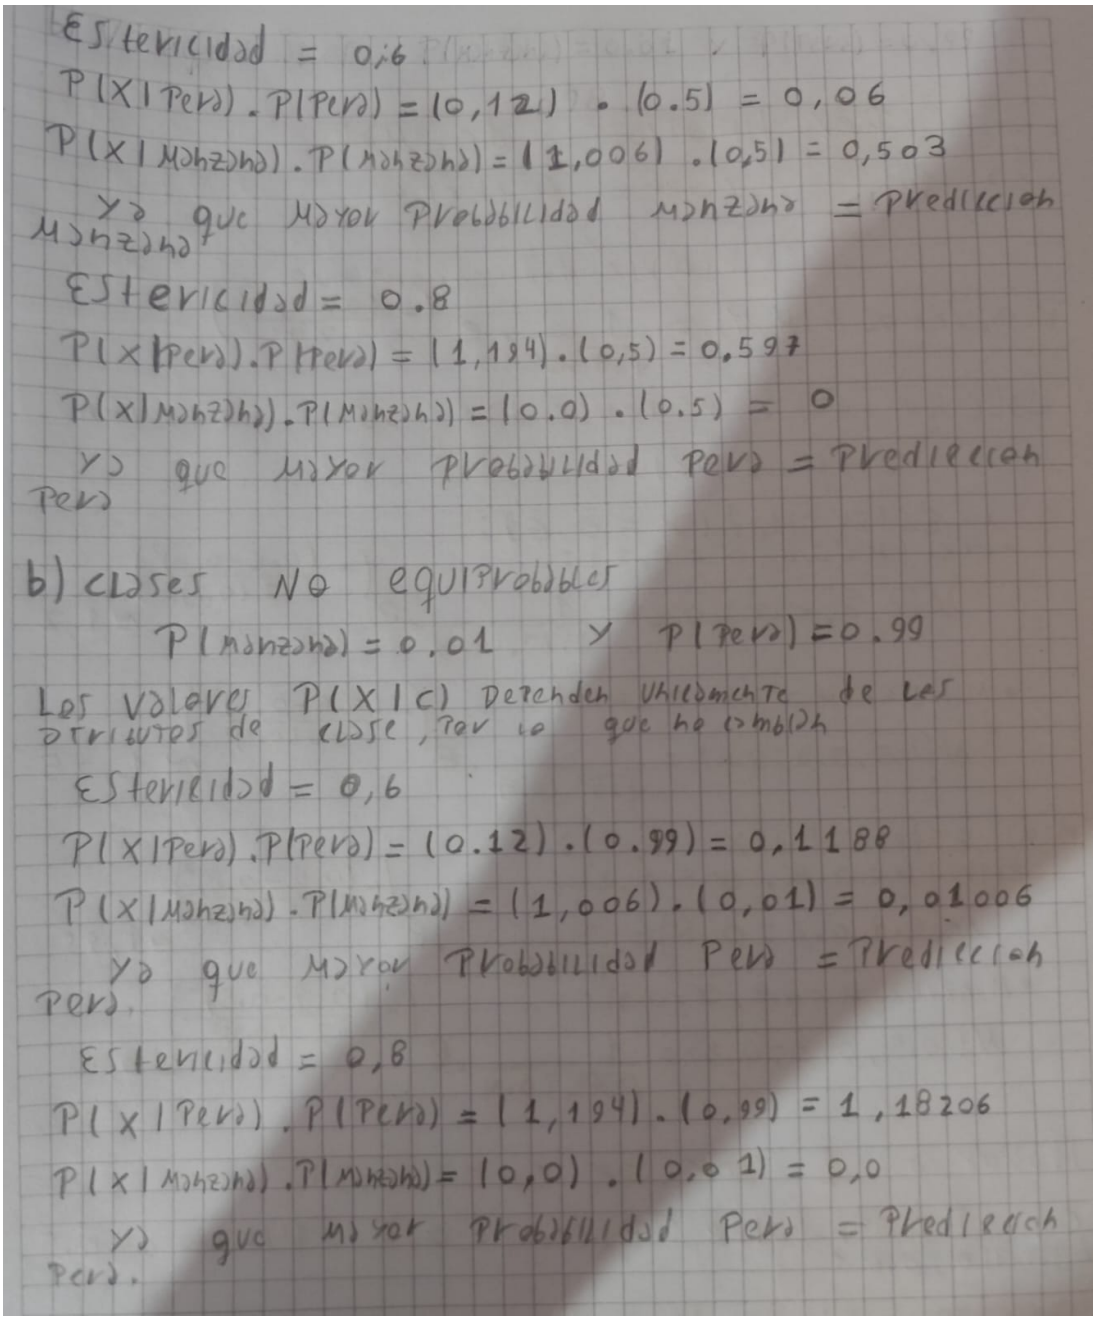


Figura 2: Desarrollo manuscrito del Inciso B.

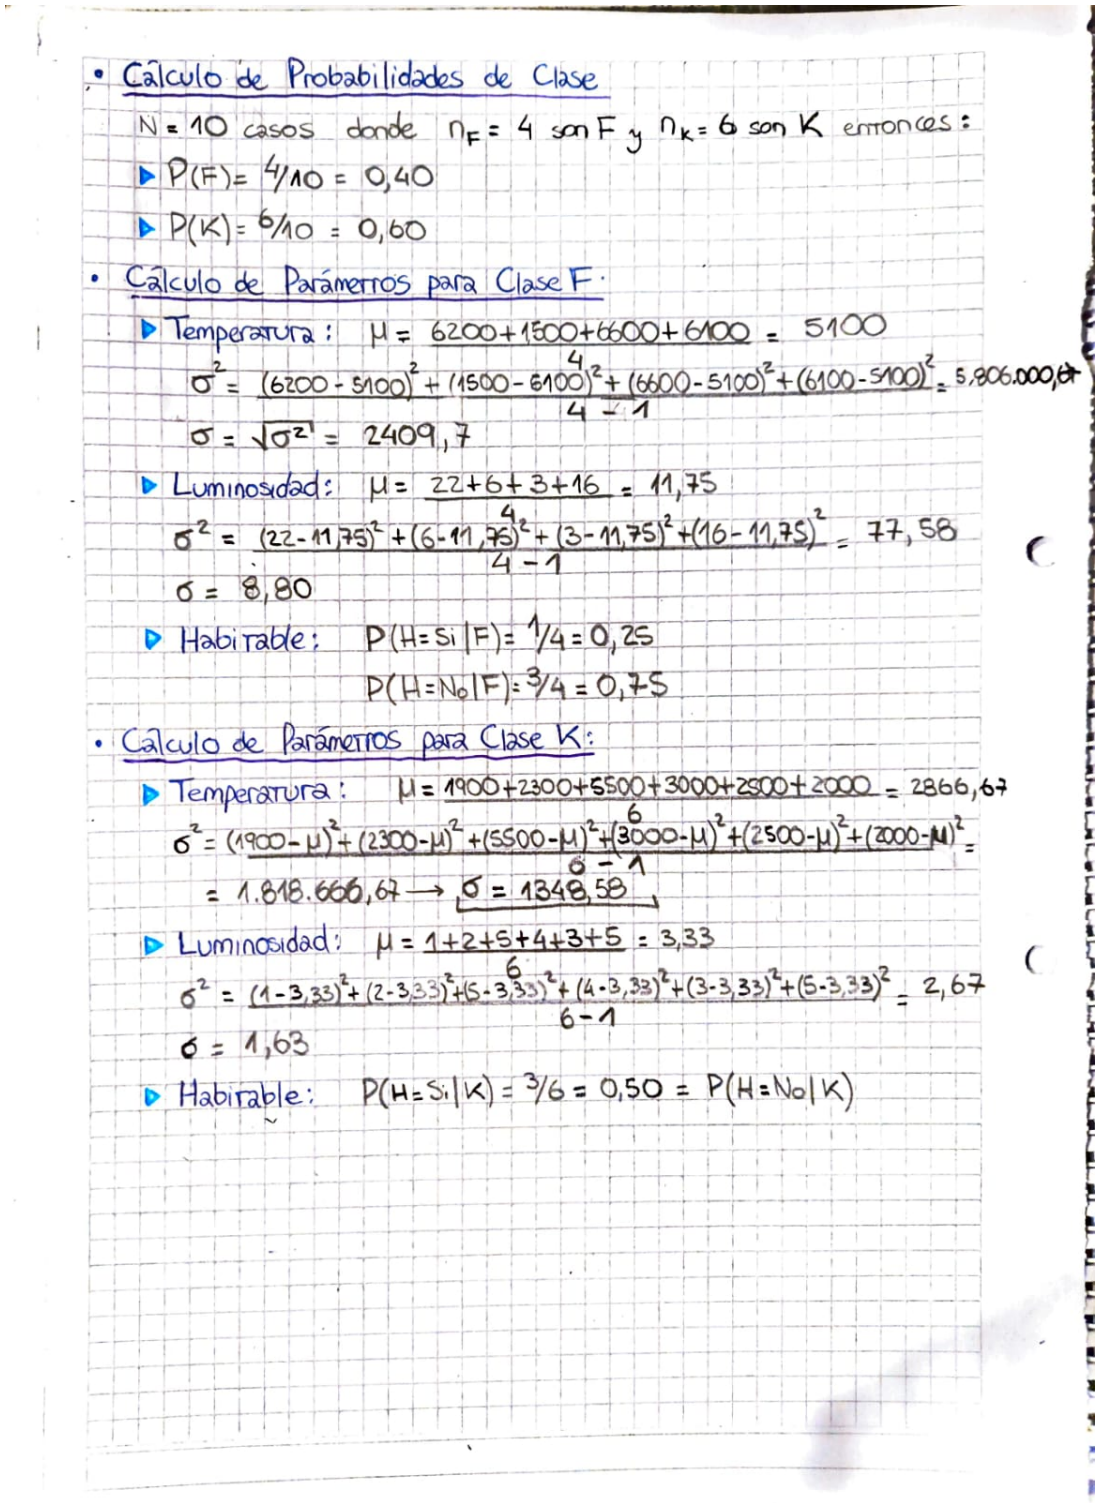


Figura 3: Desarrollo manuscrito del Inciso A.

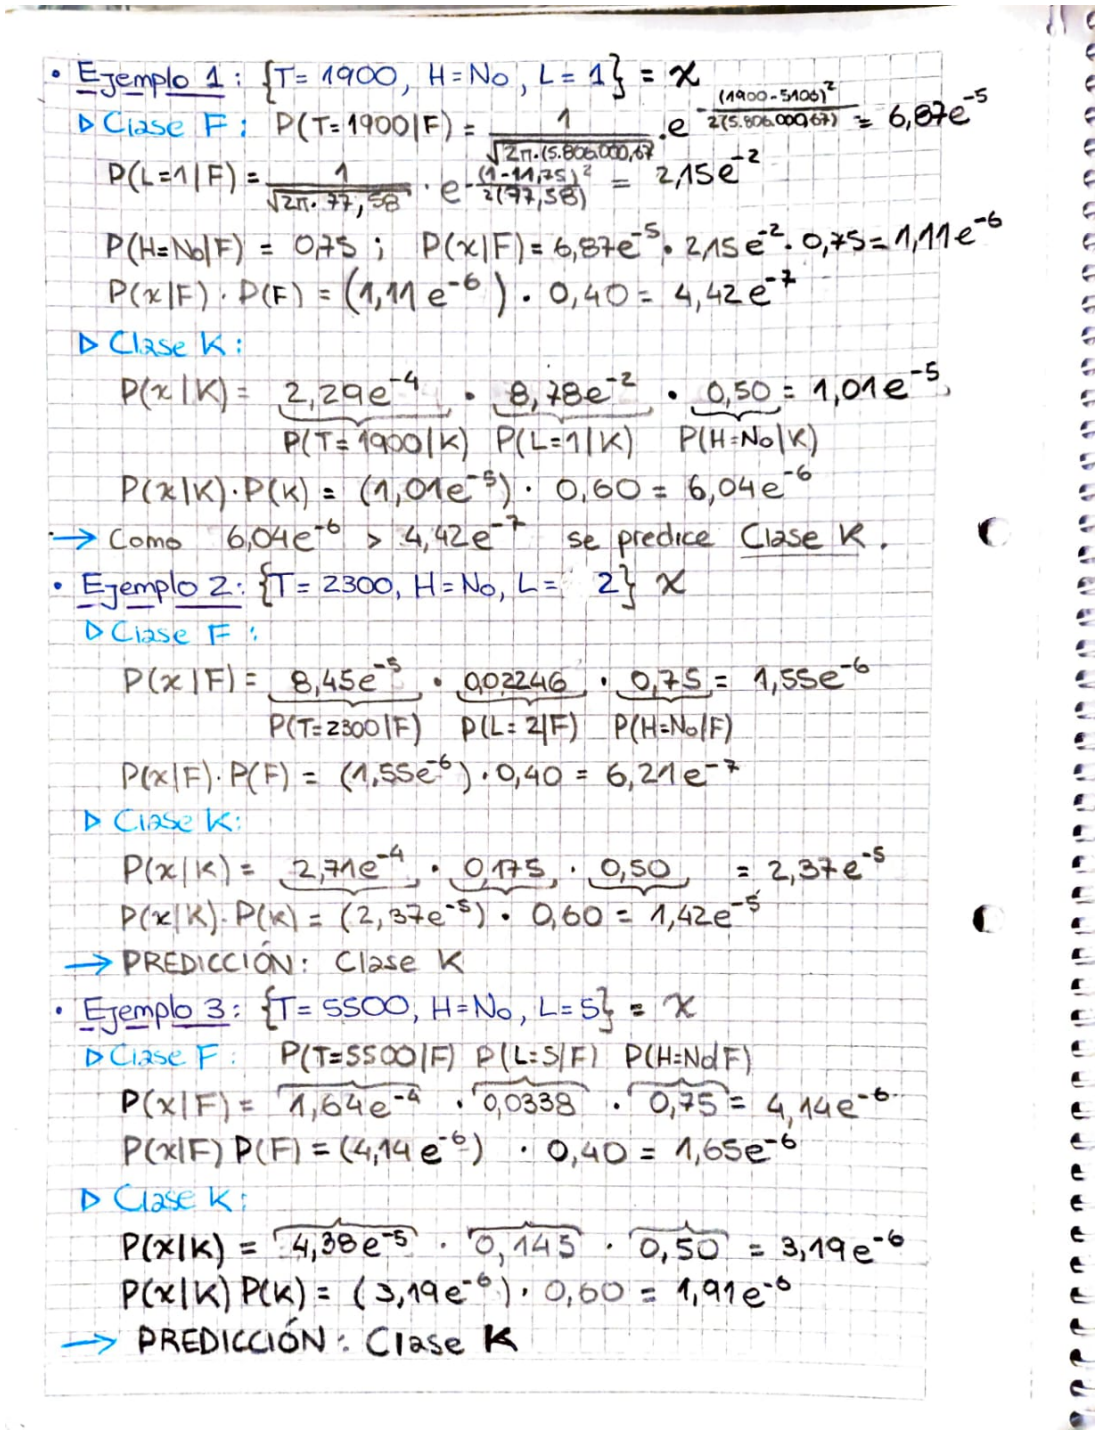


Figura 4: Desarrollo manuscrito del Inciso B.