Minería de Datos usando Sistemas Inteligentes



Trabajo Práctico 4

Arboles de clasificacion

Grupo: 1

Tutor: Oscar Agustín Stanchi

Integrantes:

- Lopez, Matias 02670/0
- Silicaro Pera, Isidro 03326/9
- Pacchialat, Taciano 03358/8



5. Construcción de árboles

a) Construcción manual del árbol de clasificación C4.5

A continuación se detalla la construcción manual de un árbol de clasificación C4.5 sin poda, utilizando la Ganancia de Información como criterio sobre los datos del archivo **trabajos_ej4_train.csv**. El objetivo es predecir si una persona obtendrá o no el trabajo según sus antecedentes.

A continuación se presentan los datos del conjunto de entrenamiento utilizados:

Instancia	Título universitario	Experiencia en el cargo	Cantidad de Trabajos Anteriores	Trabaja actualmente	Obtiene trabajo
0	SI	BAJA	6	SI	SI
1	NO	BAJA	6	NO	NO
2	NO	ALTA	6	NO	NO
3	NO	ALTA	6	NO	NO
4	NO	MEDIA	6	SI	NO
5	SI	BAJA	6	NO	SI
6	NO	BAJA	6	SI	NO
7	NO	ALTA	8	SI	SI
8	SI	ALTA	8	NO	SI
9	NO	MEDIA	8	SI	NO
10	NO	BAJA	6	NO	NO
11	NO	MEDIA	6	NO	NO
12	NO	MEDIA	6	NO	NO
13	SI	ALTA	9	SI	SI
14	NO	MEDIA	9	SI	SI
15	NO	MEDIA	9	NO	SI

Tabla 1: Conjunto de datos de entrenamiento para la construcción del árbol.

En cada paso se presentan los valores de Entropía y Ganancia de Información para cada atributo evaluado.

Los desarrollos manuscritos de los cálculos y las divisiones sucesivas pueden consultarse de forma detallada en el **Anexo: Procedimientos Manuscritos** al final de este documento. La verificación de estos resultados se realizó contrastándolos con los scripts de Python provistos teóricamente.

c) Accuracy del árbol en el conjunto de entrenamiento

El accuracy obtenido tras evaluar el árbol construido sobre el propio conjunto de entrenamiento es:

$$\text{Accuracy}_{\text{train}} = \text{Valor}$$

7. Efecto del tamaño del árbol

En esta sección se analiza cómo la variación de los hiperparámetros impacta en el tamaño del árbol y en su rendimiento tanto en el conjunto de entrenamiento como de testeo. Se utilizó el archivo **diabetes_nominal_train** para el entrenamiento y **diabetes_nominal_test.xlsx** para la evaluación, empleando *information gain* como medida de desorden y *min_error_decrease* = 0,01.

a) Árbol con min_samples_split = 40 y min_samples_leaf = 20

b) Árbol con min_samples_split = 100 y min_samples_leaf = 50

c) Árbol con min_samples_split = 20 y min_samples_leaf = 10

d) Análisis y Conclusiones

¿Qué ocurre con el tamaño y complejidad del árbol en cada caso?
¿Se observan diferencias en la performance del árbol en ambos conjuntos de datos? ¿A qué se deben estas diferencias?

A modo de resumen, se presenta la siguiente tabla con los resultados de cada inciso:

Inciso	**c)**	**a)**	**b)**
min_samples_split	20	40	100
min_samples_leaf	10	20	50
Tamaño del árbol			
Accuracy Train			
Accuracy Test			

Tabla 2: Comparación del tamaño del árbol y accuracy para distintos hiperparámetros.

Anexo: Procedimientos Manuscritos

A continuación se adjuntan las capturas de los procedimientos y cálculos analíticos realizados manualmente para la resolución del Ejercicio 5.

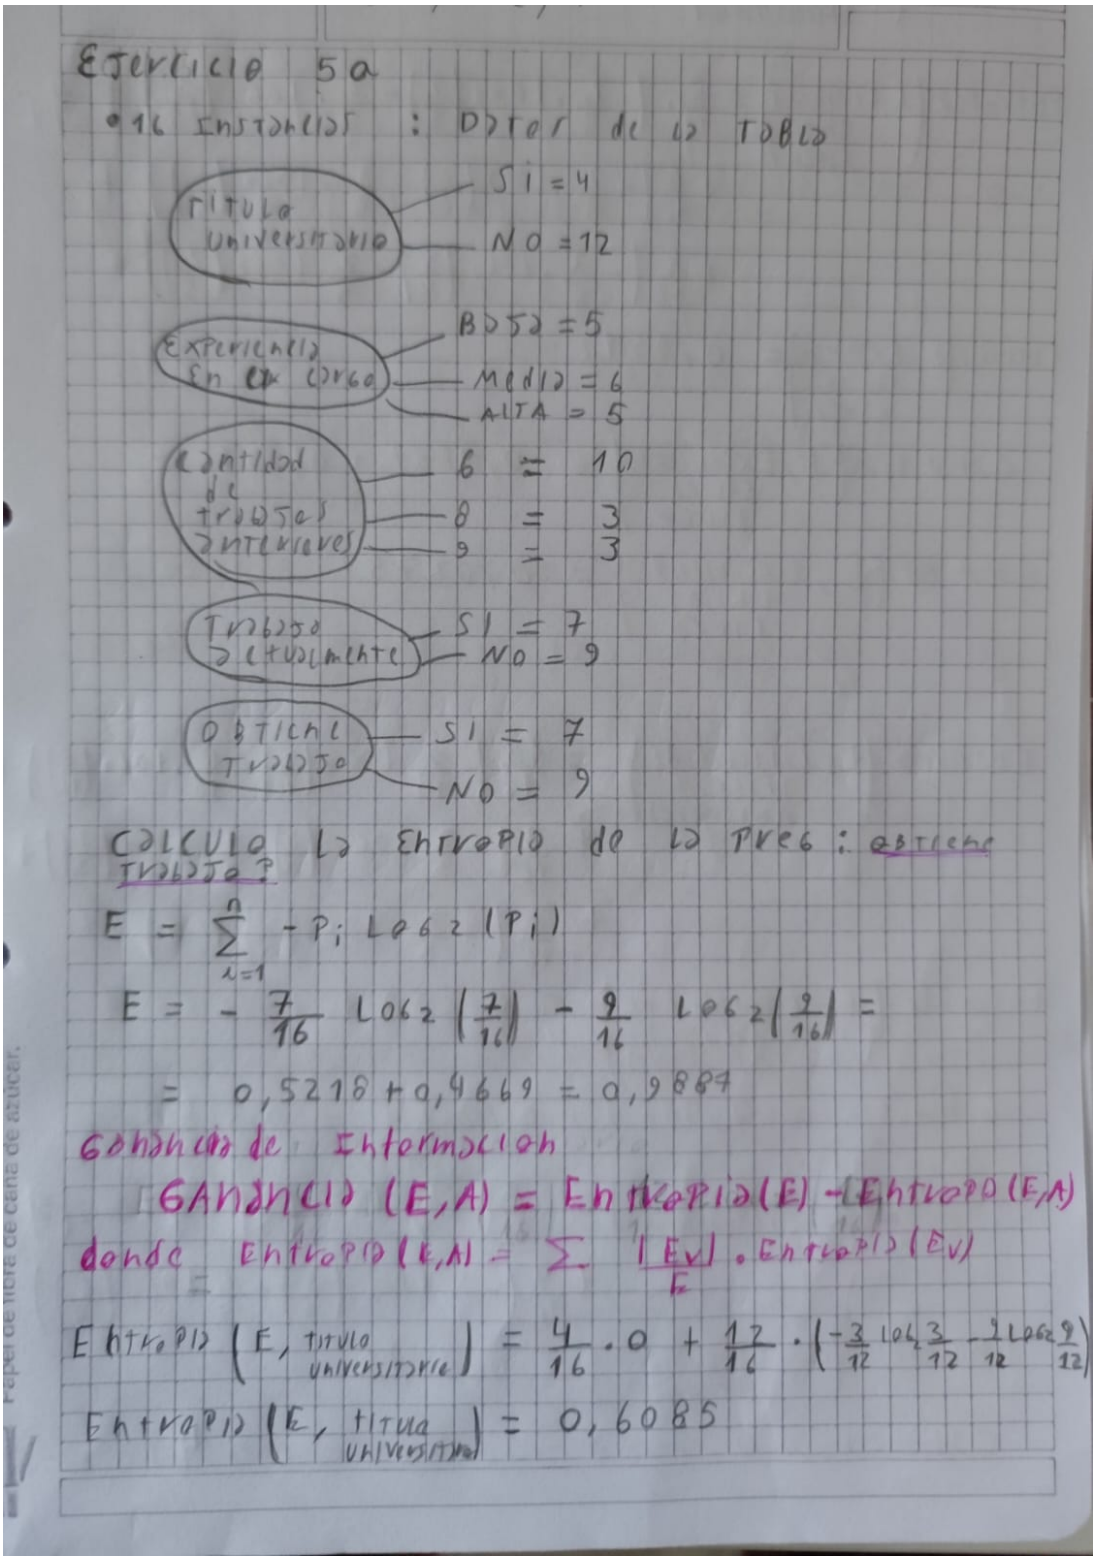


Figura 1: Desarrollo manuscrito del Inciso A - Parte 1.

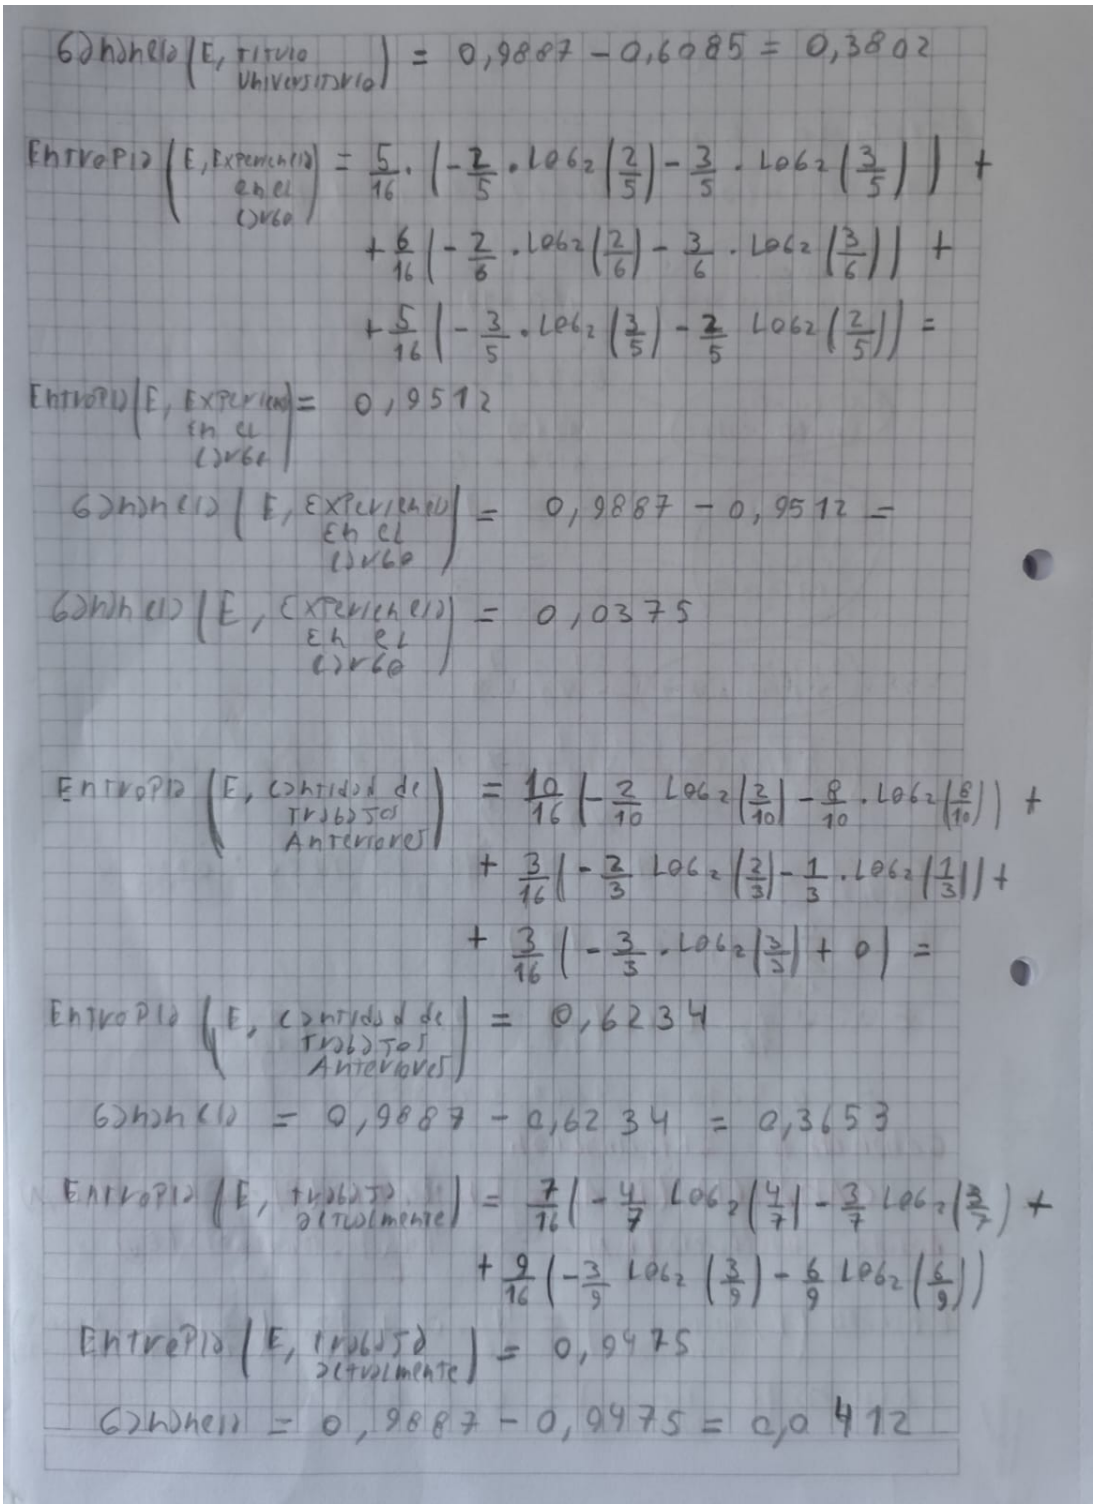


Figura 2: Desarrollo manuscrito del Inciso A - Parte 2.

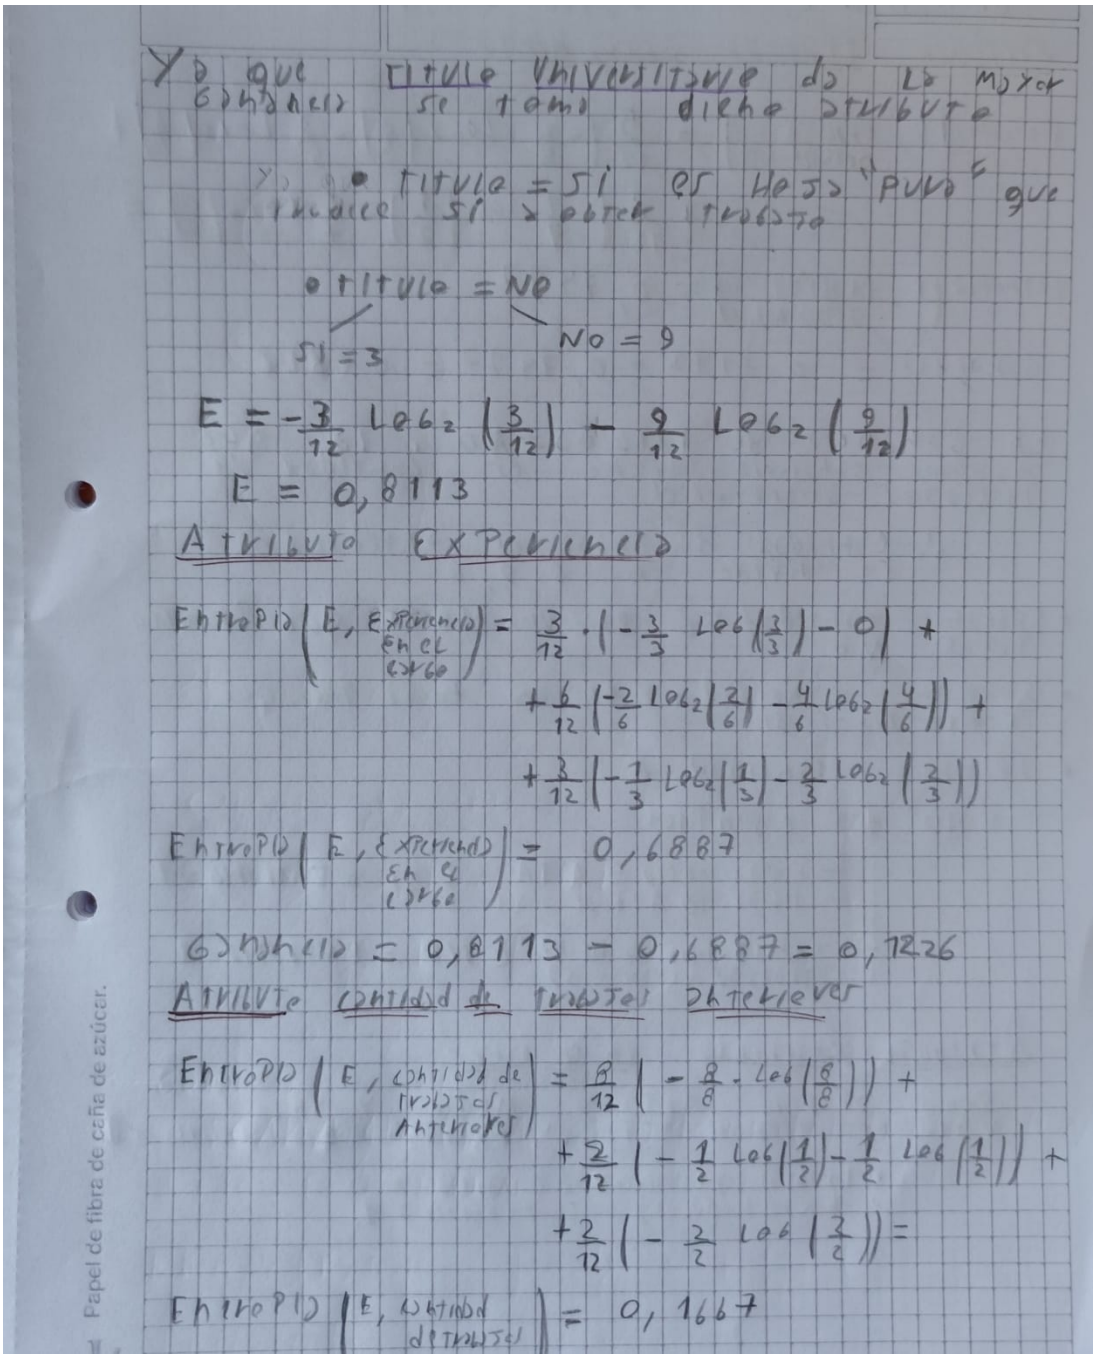


Figura 3: Desarrollo manuscrito del Inciso A - Parte 3.

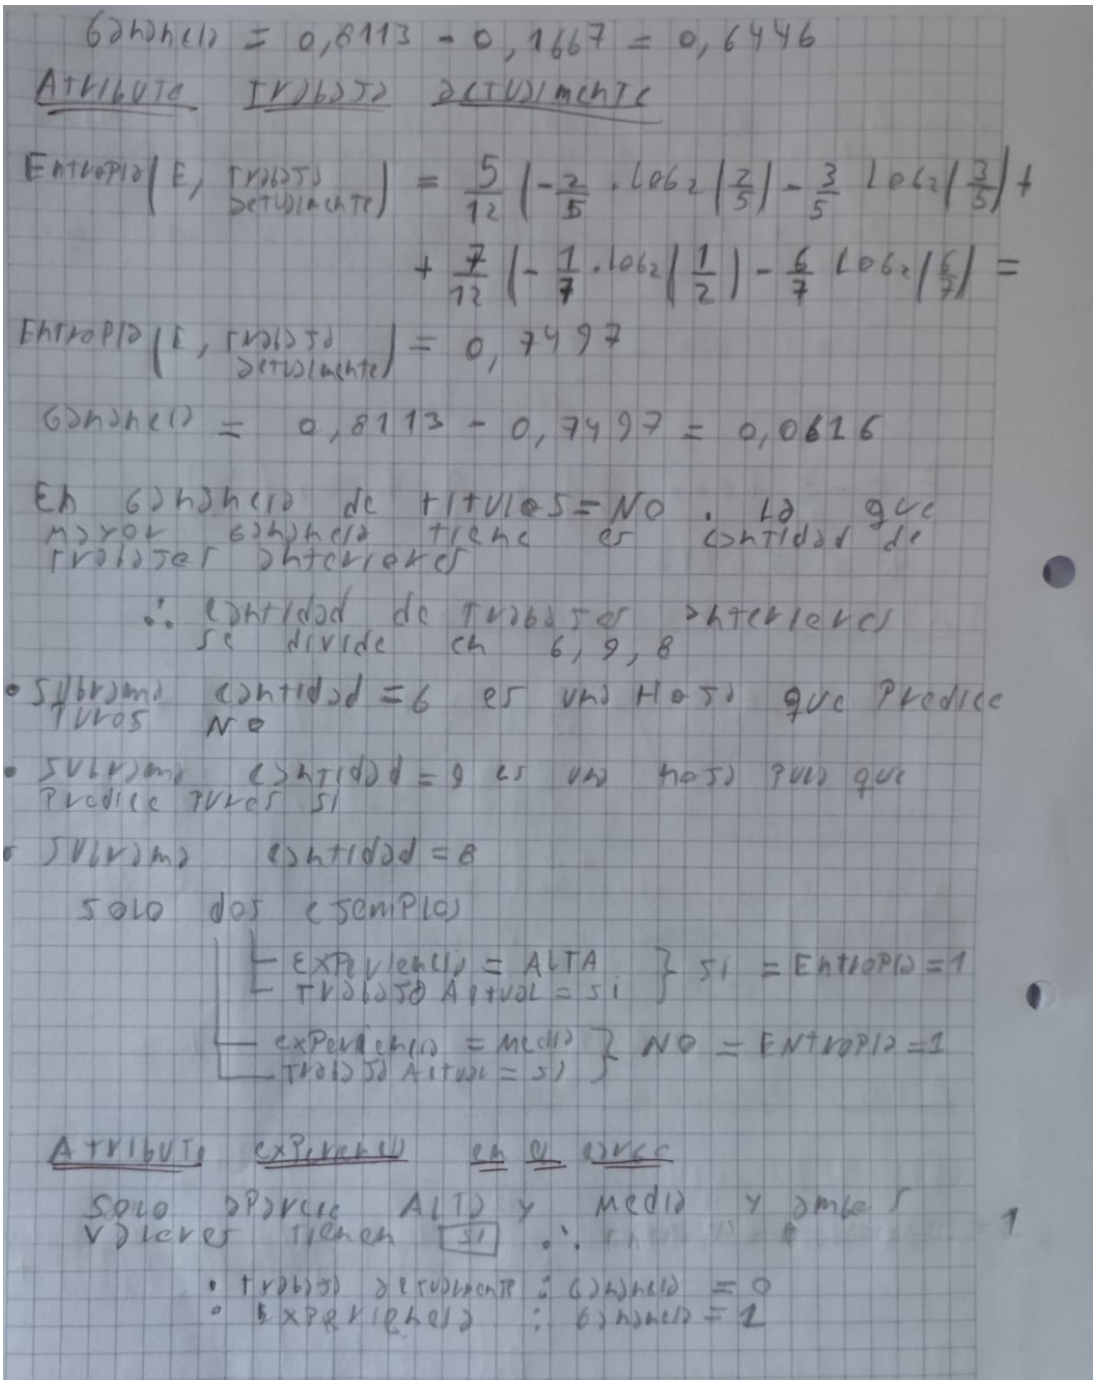


Figura 4: Desarrollo manuscrito del Inciso A - Parte 4.

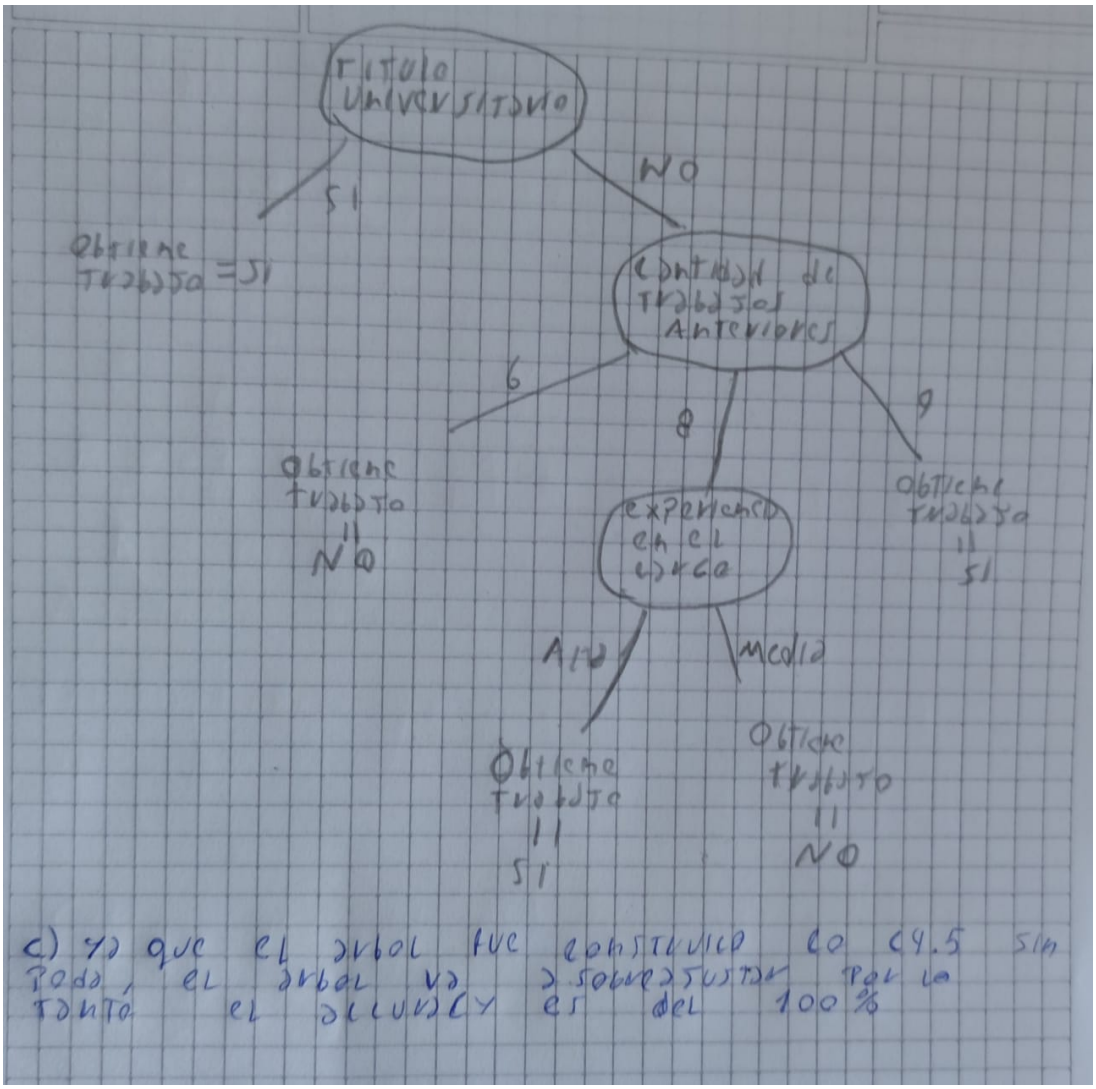


Figura 5: Desarrollo manuscrito del Inciso C.