Minería de Datos usando Sistemas Inteligentes



Trabajo Práctico 4

Arboles de clasificacion

Grupo: 1

Tutor: Oscar Agustín Stanchi

Integrantes:

- Lopez, Matias 02670/0
- Silicaro Pera, Isidro 03326/9
- Pacchialat, Taciano 03358/8



5. Construcción de árboles

a) Construcción manual del árbol de clasificación C4.5

A continuación se detalla la construcción manual de un árbol de clasificación C4.5 sin poda, utilizando la Ganancia de Información como criterio sobre los datos del archivo **trabajos_ej4_train.csv**. El objetivo es predecir si una persona obtendrá o no el trabajo según sus antecedentes.

A continuación se presentan los datos del conjunto de entrenamiento utilizados:

Instancia	Título universitario	Experiencia en el cargo	Cantidad de Trabajos Anteriores	Trabaja actualmente	Obtiene trabajo
0	SI	BAJA	6	SI	SI
1	NO	BAJA	6	NO	NO
2	NO	ALTA	6	NO	NO
3	NO	ALTA	6	NO	NO
4	NO	MEDIA	6	SI	NO
5	SI	BAJA	6	NO	SI
6	NO	BAJA	6	SI	NO
7	NO	ALTA	8	SI	SI
8	SI	ALTA	8	NO	SI
9	NO	MEDIA	8	SI	NO
10	NO	BAJA	6	NO	NO
11	NO	MEDIA	6	NO	NO
12	NO	MEDIA	6	NO	NO
13	SI	ALTA	9	SI	SI
14	NO	MEDIA	9	SI	SI
15	NO	MEDIA	9	NO	SI

Tabla 1: Conjunto de datos de entrenamiento para la construcción del árbol.

Los valores de Entropía y Ganancia de Información calculados en cada paso, así como las divisiones sucesivas, pueden consultarse de forma detallada en el **Anexo: Procedimientos Manuscritos** al final de este documento. La verificación de estos resultados se realizó contrastándolos con los scripts de Python provistos teóricamente.

c) Accuracy del árbol en el conjunto de entrenamiento

El accuracy obtenido tras evaluar el árbol construido sobre el propio conjunto de entrenamiento es:

$$\text{Accuracy}_{\text{train}} = 1{,}0$$

7. Efecto del Tamaño del Árbol

Tendremos como objetivo analizar el comportamiento y el rendimiento de los algoritmos de árboles de decisión aplicados a la clasificación. Para ello se utiliza un conjunto de datos pre-procesado con atributos nominales, facilitando la construcción de modelos basados en la ganancia de información.

La metodología será la siguiente:

- **Configuración del Modelo:** Se ajustan los parámetros de control de crecimiento del árbol, específicamente el mínimo de muestras para realizar una división (*min_samples_split*) y el mínimo de muestras permitidas en un nodo hoja (*min_samples_leaf*).
- **Entrenamiento y Evaluación:** Se entrena el clasificador utilizando el conjunto de datos `diabetes_nominal_train.xlsx` y se evalúa su desempeño frente al conjunto de prueba `diabetes_nominal_test.xlsx`.
- **Análisis de Complejidad:** Se observa la relación entre la restricción de los parámetros y el tamaño resultante del árbol (medido en cantidad de nodos), contrastando estos resultados con las tasas de acierto (*accuracy*) obtenidas en ambas etapas.

A través de esta comparativa, se busca identificar el fenómeno de sobreajuste (*overfitting*) y determinar cómo la variación en el tamaño de la estructura del árbol impacta directamente en su capacidad de generalización sobre datos no observados durante el entrenamiento.

a) Estructura del Árbol A

```
Root
|   Glucose=range4 [140.500 - ∞] =>
|   |   Pregnancies=range3 [3.500 - 6.500] => ♣ [0.45238095
0.54761905]
|   |   Pregnancies=range4 [6.500 - ∞] => ♣ [0.16071429 0.83928571]
|   |   Pregnancies=range2 [1.500 - 3.500] => ♣ [0.33333333
0.66666667]
|   |   Pregnancies=range1 [-∞ - 1.500] => ♣ [0.425 0.575]
|   Glucose=range1 [-∞ - 99.500] =>
|   |   BMI=range4 [36.650 - ∞] => ♣ [0.47826087 0.52173913]
|   |   BMI=range1 [-∞ - 27.350] => ♣ [1. 0.]
|   |   BMI=range2 [27.350 - 32.050] => ♣ [0.89473684 0.10526316]
|   |   BMI=range3 [32.050 - 36.650] => ♣ [0.90909091 0.09090909]
|   Glucose=range3 [117.500 - 140.500] =>
|   |   BMI=range4 [36.650 - ∞] => ♣ [0.51219512 0.48780488]
|   |   BMI=range1 [-∞ - 27.350] => ♣ [0.89189189 0.10810811]
|   |   BMI=range2 [27.350 - 32.050] => ♣ [0.54761905 0.45238095]
|   |   BMI=range3 [32.050 - 36.650] => ♣ [0.48 0.52]
|   Glucose=range2 [99.500 - 117.500] =>
|   |   Age=range3 [29.500 - 41.500] => ♣ [0.525 0.475]
|   |   Age=range4 [41.500 - ∞] => ♣ [0.6 0.4]
|   |   Age=range1 [-∞ - 24.500] =>
|   |   |   BMI=range1 [-∞ - 27.350] => ♣ [0.96 0.04]
|   |   Age=range2 [24.500 - 29.500] => ♣ [0.84090909 0.15909091]
```

Figura 1: Estructura del árbol de decisión para el inciso (a).

b) Estructura del Árbol B

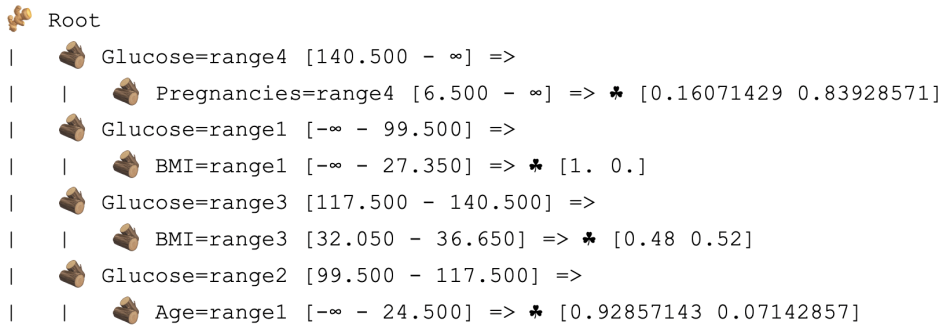


Figura 2: Estructura del árbol de decisión con pre-poda estricta, inciso (b).

c) Estructura del Árbol C

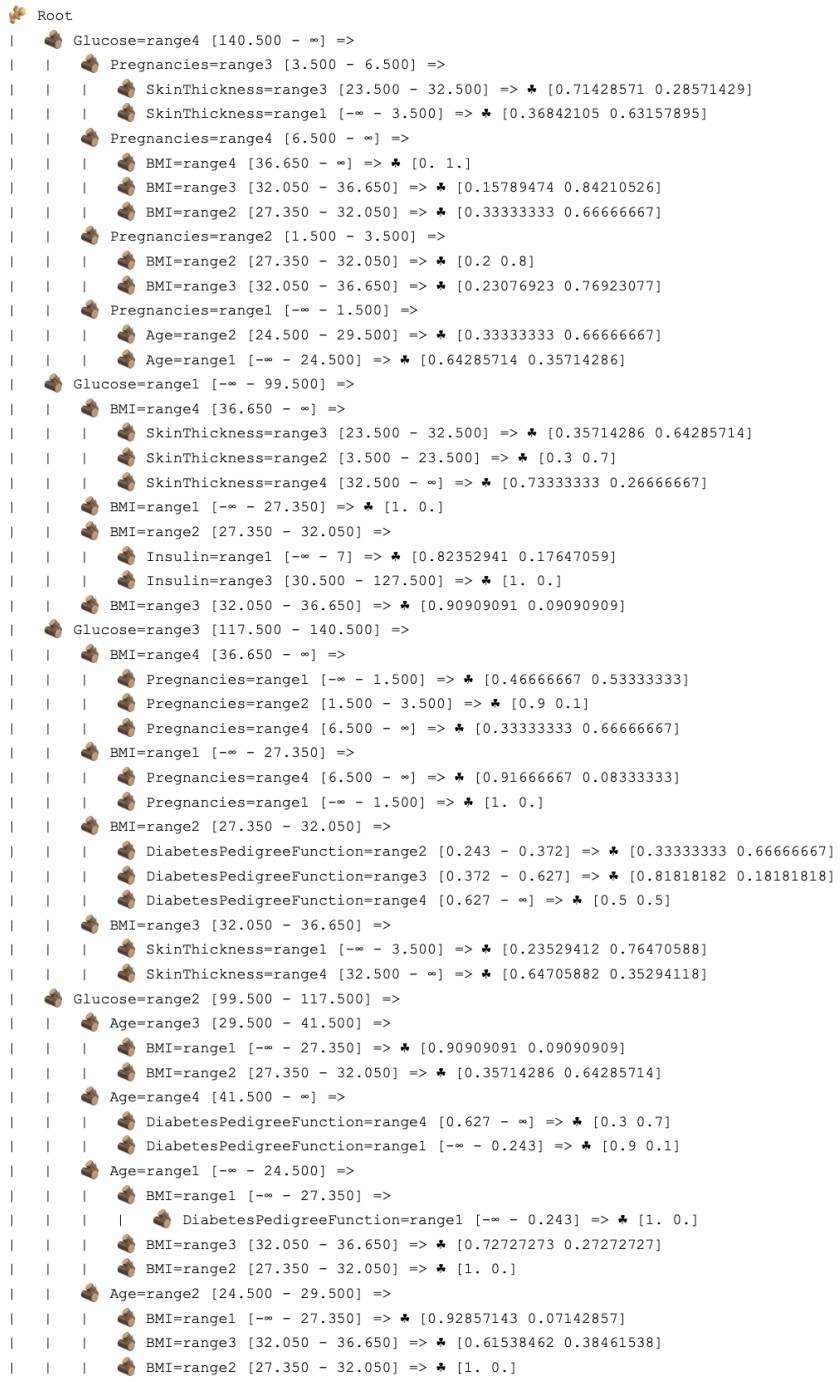


Figura 3: Estructura del árbol de decisión para el inciso (c).

7.1 Tabla de Resultados

Inciso	**c)**	**a)**	**b)**
min_samples_split	20	40	100
min_samples_leaf	10	20	50
Tamaño del árbol	56	22	9
Accuracy Train	0.7728	0.7164	0.7135
Accuracy Test	0.5584	0.5844	0.5455

Tabla 2: Comparación de parámetros y resultados de los árboles de decisión.

Anexo: Procedimientos Manuscritos

A continuación se adjuntan las capturas de los procedimientos y cálculos analíticos realizados manualmente para la resolución del Ejercicio 5.

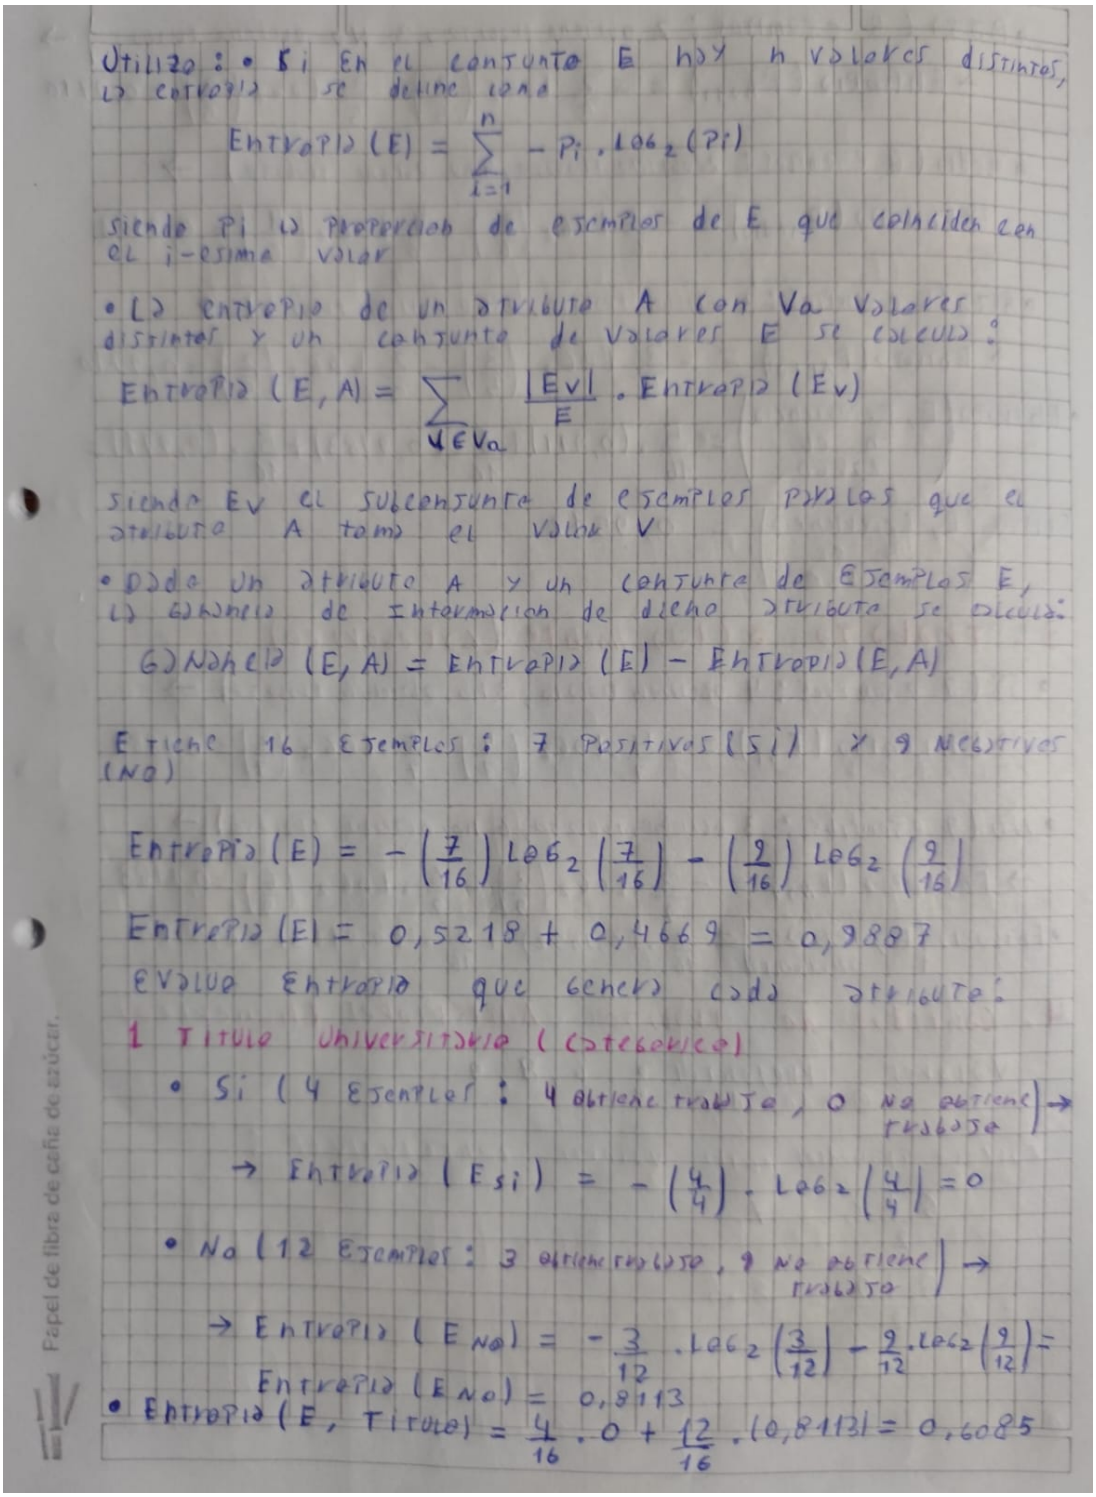


Figura 4: Desarrollo manuscrito del Inciso A - Parte 1.

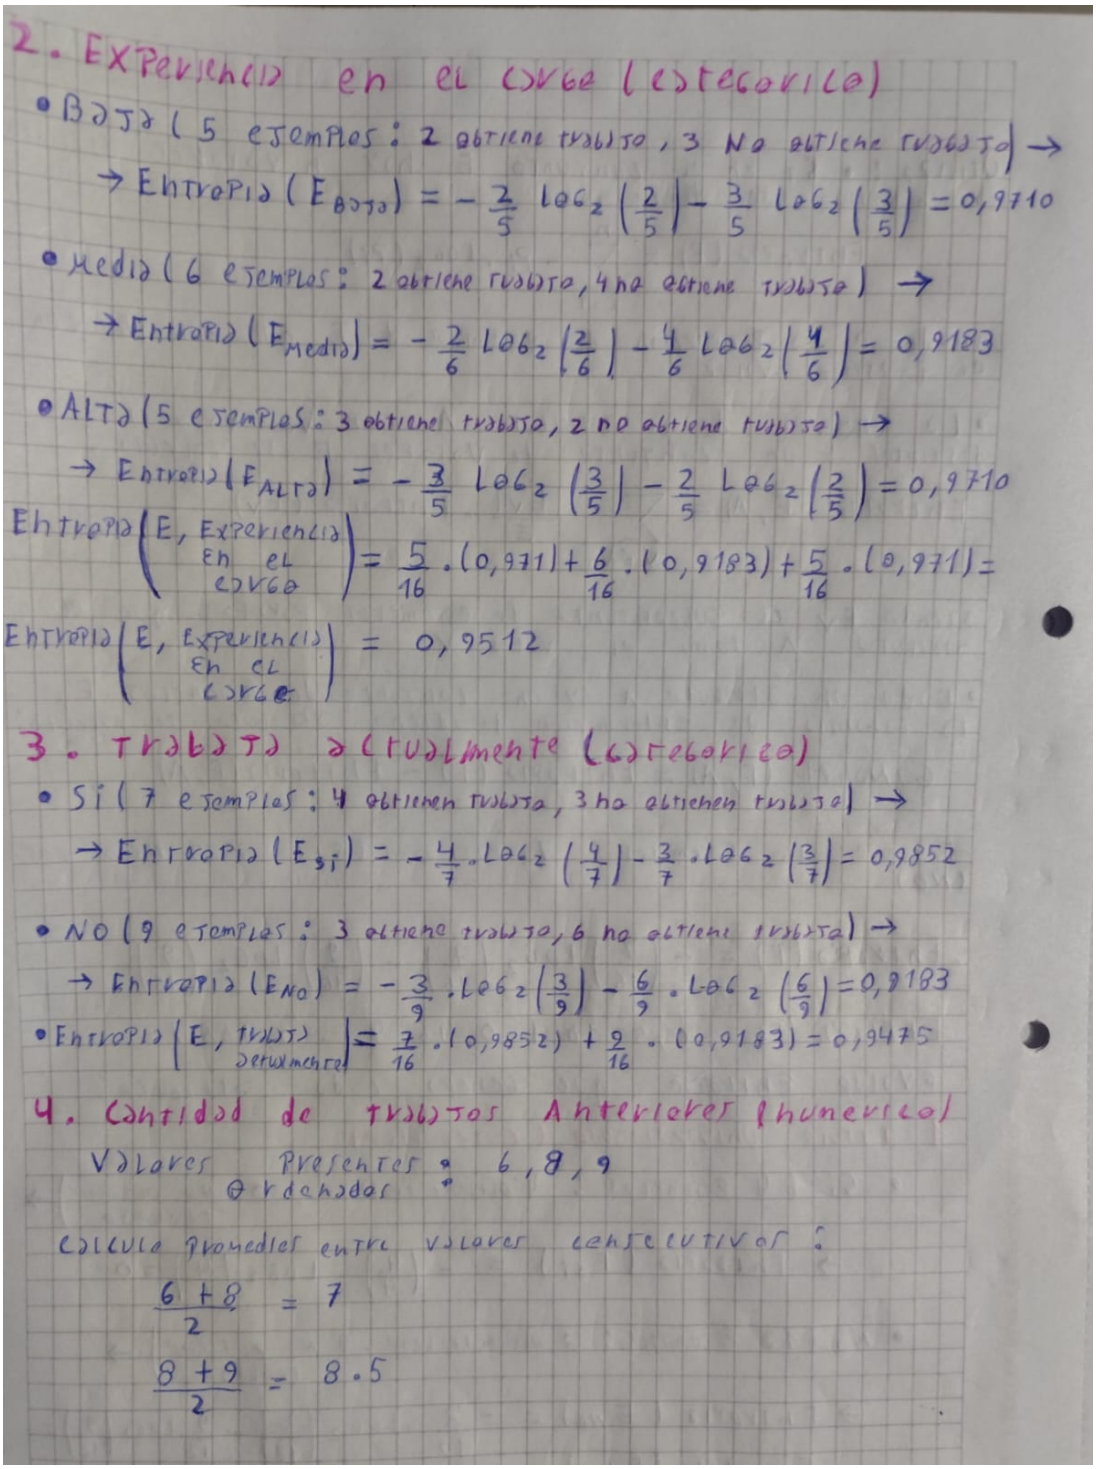


Figura 5: Desarrollo manuscrito del Inciso A - Parte 2.

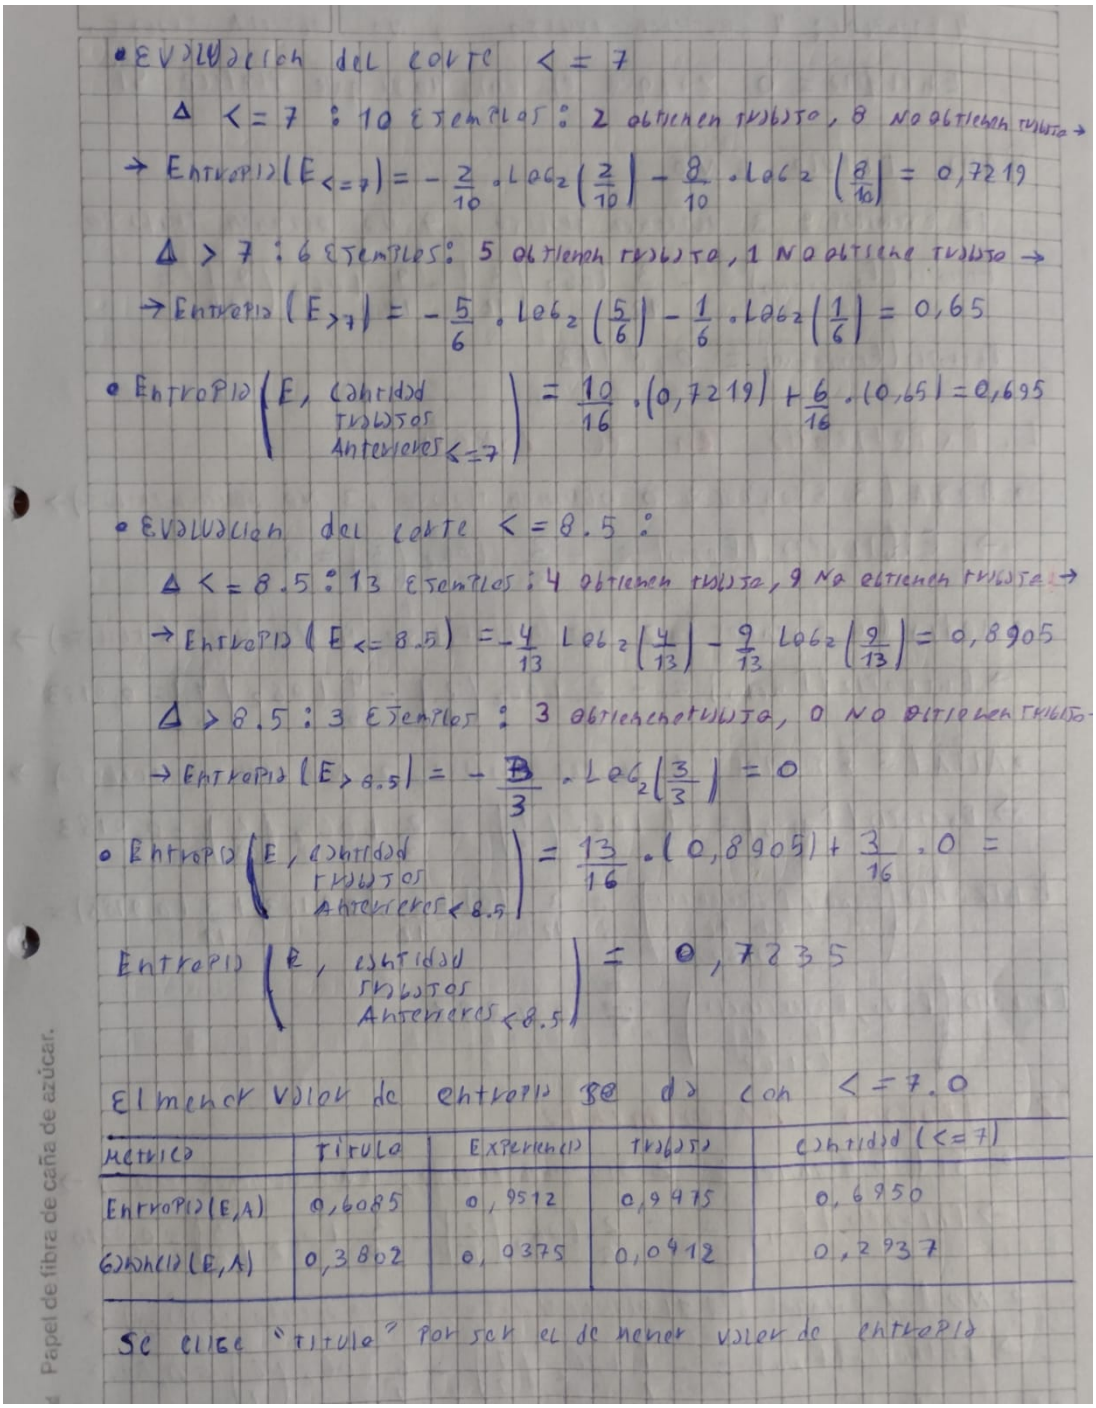


Figura 6: Desarrollo manuscrito del Inciso A - Parte 3.

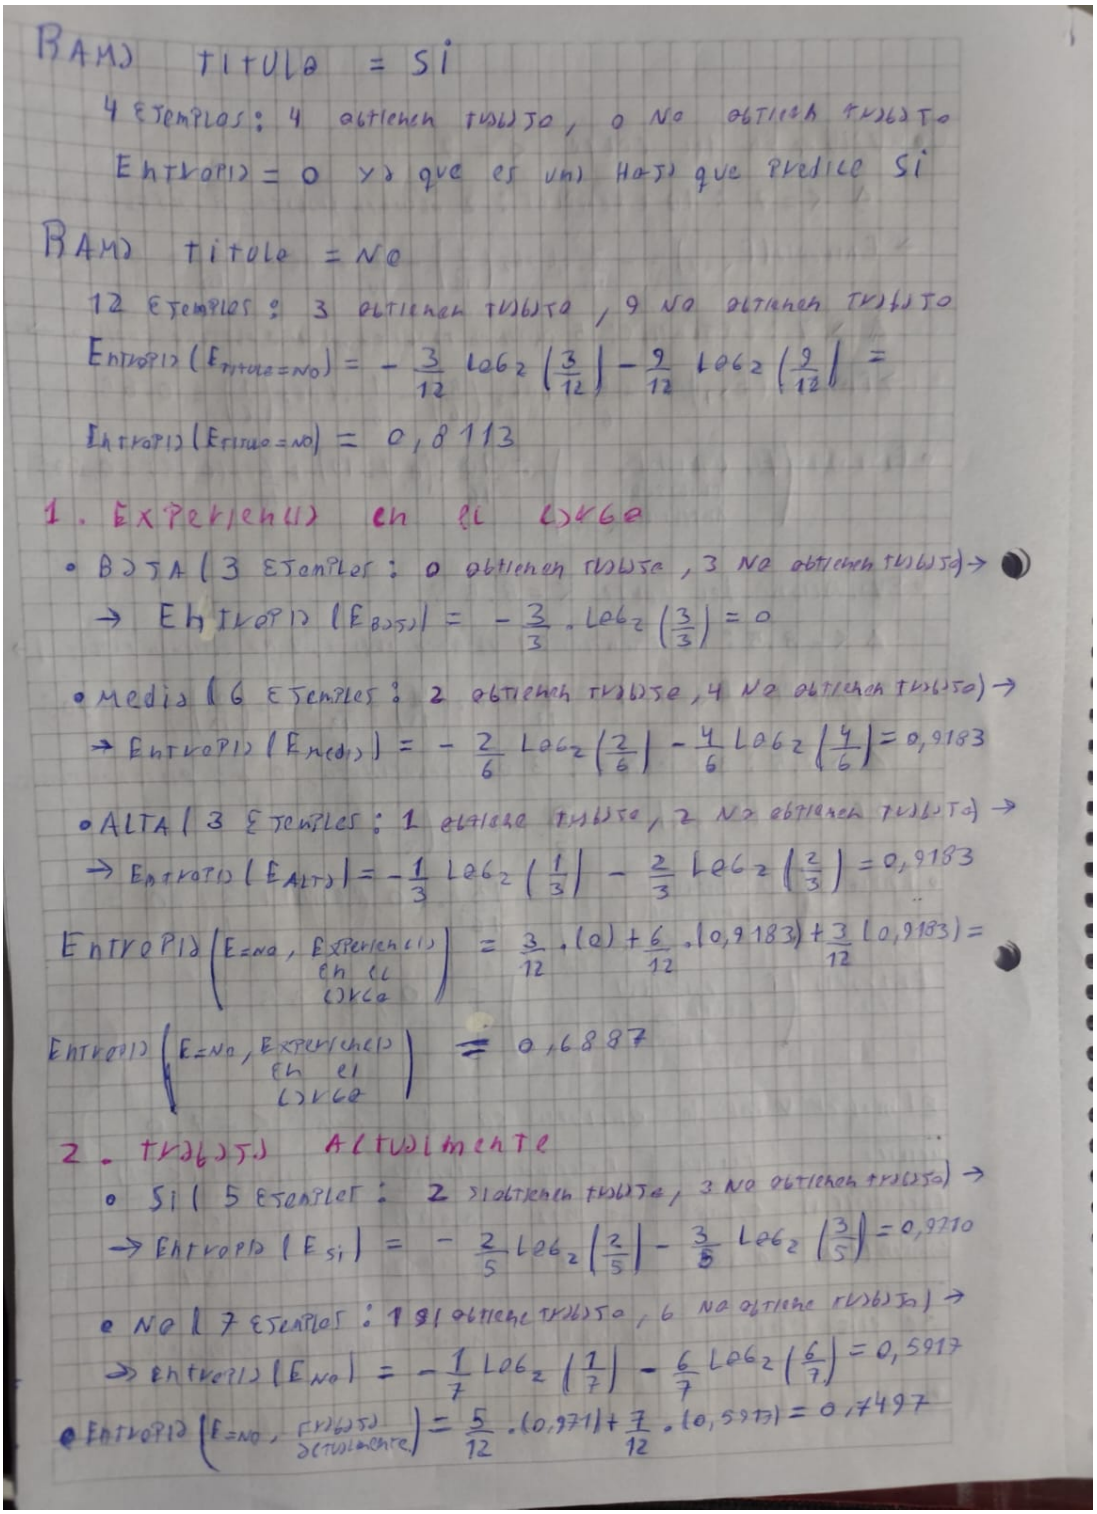


Figura 7: Desarrollo manuscrito del Inciso A - Parte 4.

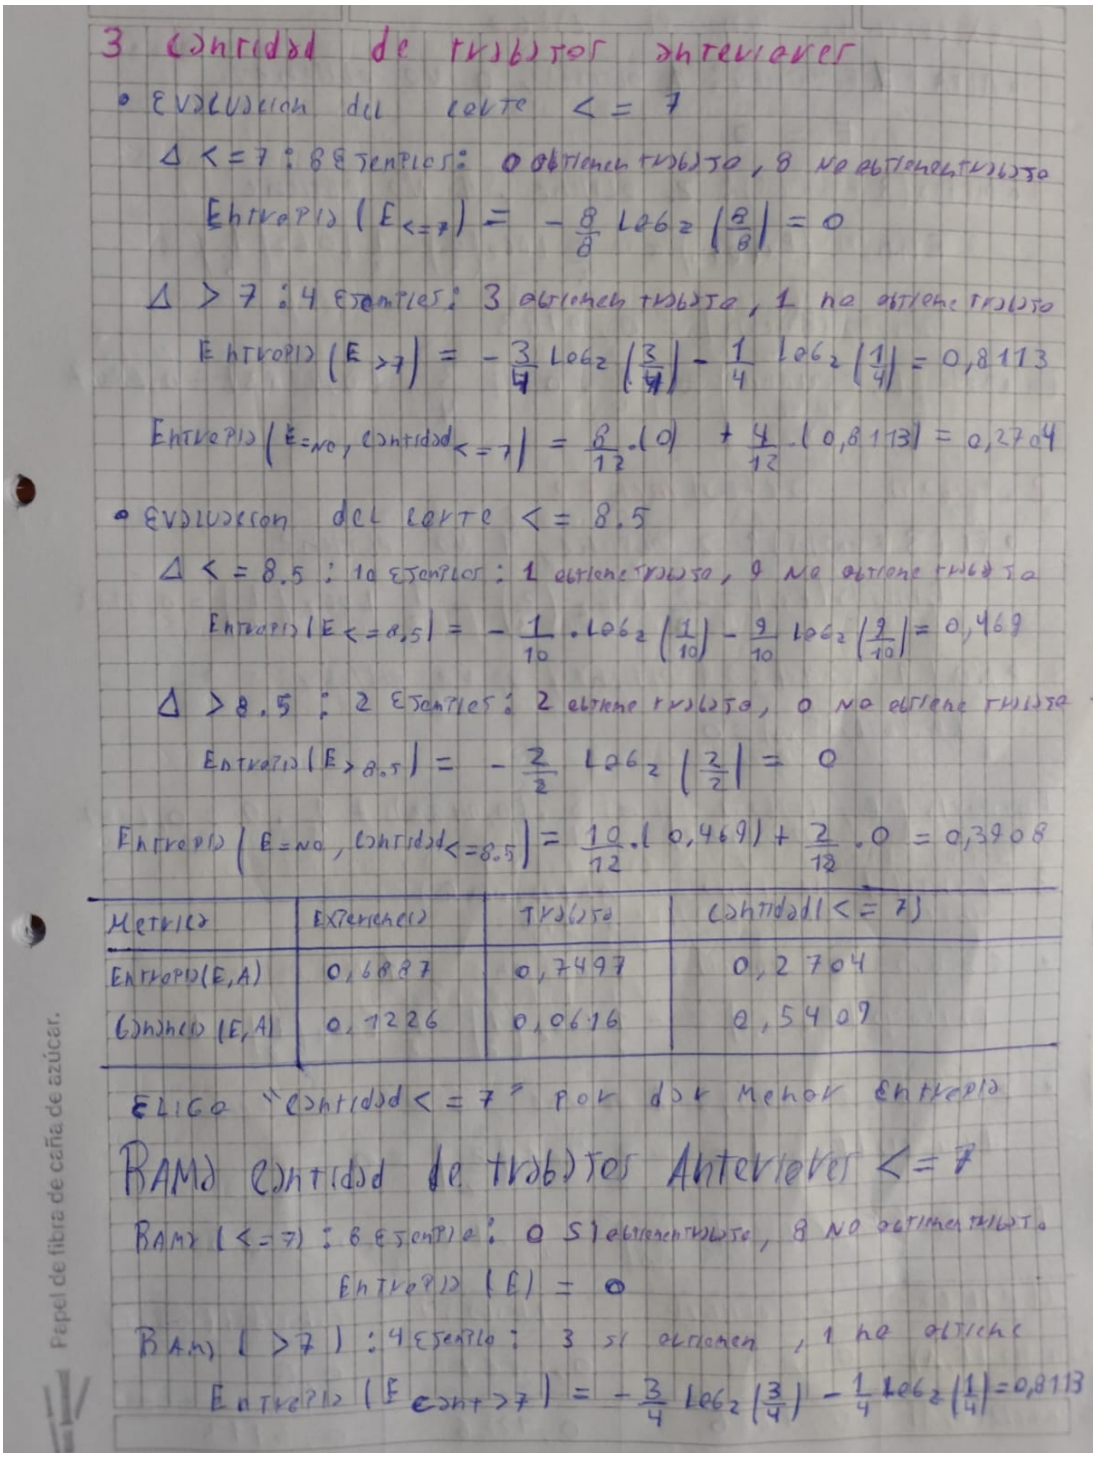


Figura 8: Desarrollo manuscrito del Inciso A - Parte 5.

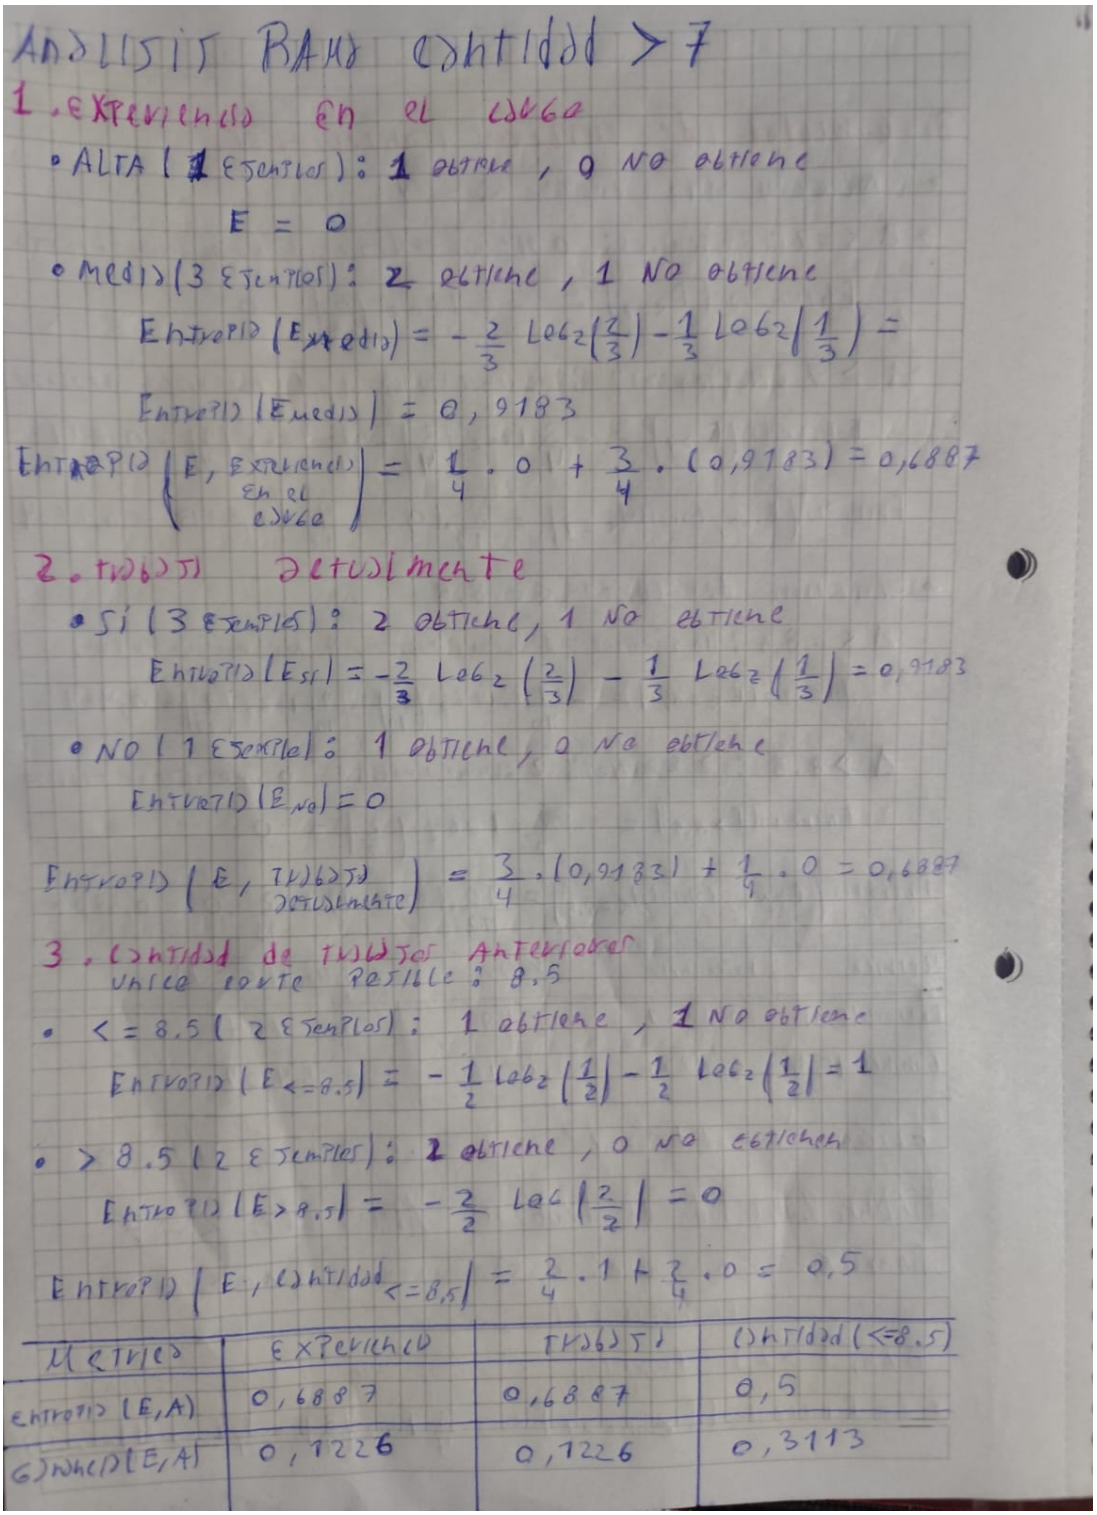


Figura 9: Desarrollo manuscrito del Inciso A - Parte 6.

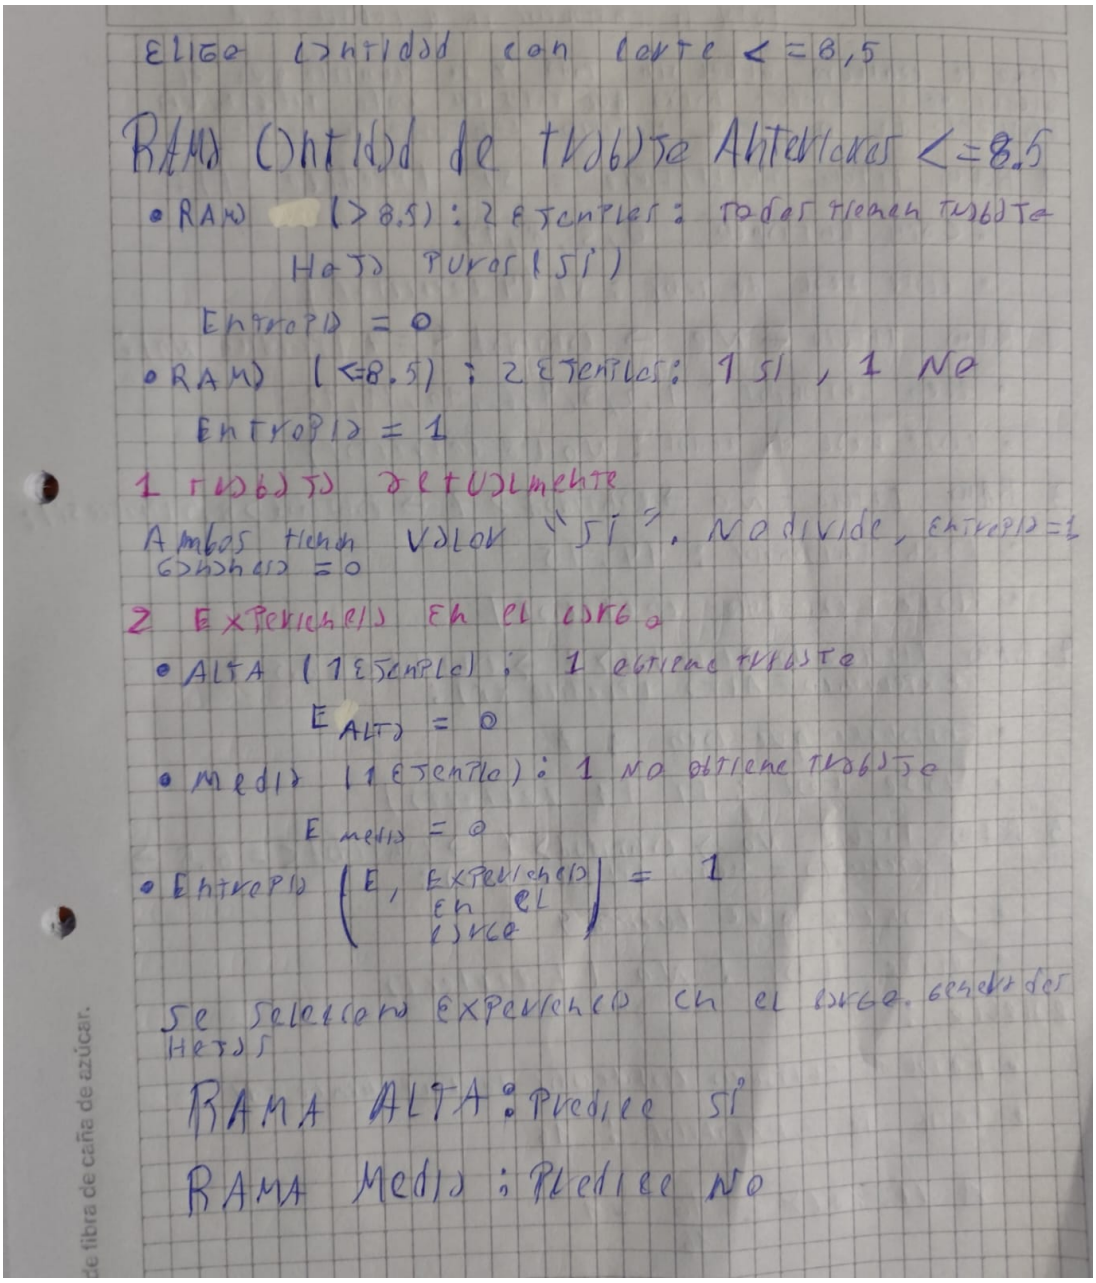


Figura 10: Desarrollo manuscrito del Inciso A - Parte 7.

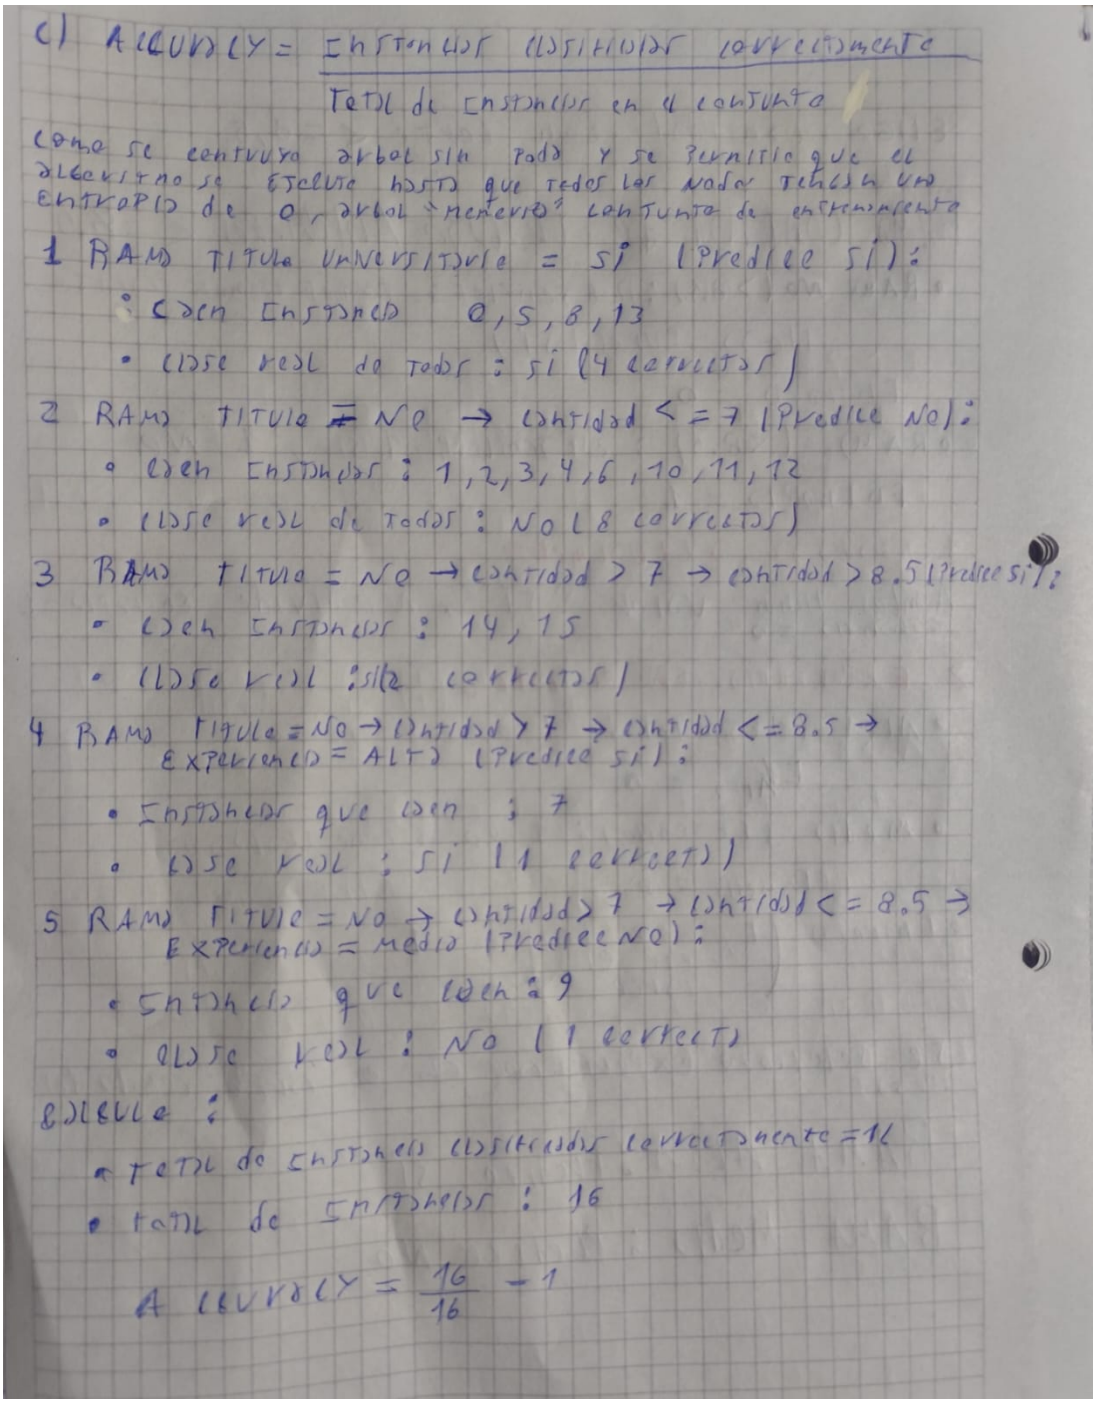


Figura 11: Desarrollo manuscrito del Inciso C.