Elección y Descripción del Conjunto de Datos, Grupo 1

Matías López, Isidro Silicaro Pera, Taciano Pacchialat

1. Introducción

En este trabajo se utilizará el conjunto de datos *UFC Datasets 1994-2025*, disponible en Kaggle bajo el nombre https://www.kaggle.com/datasets/neelagiriaditya/ufc-datasets-1994-2025.

El dataset fue seleccionado porque agrupa de manera detallada el historial de peleas de la compañía de artes marciales mixtas UFC (Ultimate Fighting Championship), sus atributos físicos, técnicas y resultados de los combates a lo largo de más de 30 años. Esta información presenta una oportunidad muy valiosa para realizar tareas de análisis de datos, estudiar las evoluciones de estilos de pelea, examinar estadísticas entre peleadores (esquinas roja y azul) y estimar probabilidades sobre resultados de combates.

El objetivo del trabajo es construir conocimiento descriptivo y probabilístico a partir de la información histórica para apoyar decisiones en escenarios de combate y entrenamiento.

En particular, se busca responder preguntas como las siguientes:

- ¿Qué luchador tiene mayor probabilidad de ganar una pelea dada?
- Si soy un luchador con determinadas características, ¿qué tipo de pelea me conviene aceptar?
- Si soy una persona con determinadas características, ¿qué estilo me conviene practicar?

2. Origen y características generales

El conjunto de datos unificado `UFC.csv` disponible como parte de los datasets de UFC contiene **8.337 registros** y **124 columnas**. Reúne una vasta cantidad de atributos capturados a lo largo de décadas mostrando un detallado registro por cada pelea que ocurrió en diversas locaciones del mundo a partir de 1994 hasta inicios de 2025.

De manera general, el conjunto de datos clasifica su información en las siguientes partes:

- Variables de contexto de evento: nombre del evento, fecha, locación y división de peso (ej. Lightweight, Heavyweight).
- Variables del combate: tiempo total de combate, si es o no por el título, y método de finalización de la pelea (sumisión, nocaut, decisión, etc.).
- Variables específicas por rincón (Rojo `r_` y Azul `b_`): información que se recolecta del peleador antes y durante el combate, que abarca desde la edad, postura y dimensiones físicas, hasta métricas clave de desempeño en la pelea como precisión de los golpes, intentos de derribo (takedowns), control en el suelo, y otros tipos de agresiones.

- Variables de salida: resultado observado de la pelea indicando quién fue el vencedor del enfrentamiento.

3. Descripción completa de las columnas

Dado el gran número de dimensiones (124), se describe la totalidad de columnas del archivo `UFC.csv` agrupándolas por su función analítica. De esta manera, no se toma solo una fracción de variables, sino todo el esquema disponible.

Cuadro 1: Cobertura completa de columnas del dataset UFC (124 columnas).

Columnas incluidas	**Descripción**
`event_id,event_name,date,location`	Identificación y contexto temporal/geográfico del evento.
`fight_id,division,title_fight, method,finish_round,match_time_ sec,total_rounds,referee`	Datos estructurales del combate: categoría, modalidad de cierre, duración y arbitraje.
`r_name,r_id,r_nick_name,r_dob,r_ stance`	Identidad y perfil básico del peleador del rincón rojo.
`r_height,r_weight,r_reach`	Características físicas del peleador del rincón rojo.
`r_wins,r_losses,r_draws`	Historial acumulado de resultados del rincón rojo.
`r_kd,r_sub_att,r_ctrl`	Métricas directas del combate para el rincón rojo: knockdowns, intentos de sumisión y tiempo/control posicional.
`r_sig_str_landed,r_sig_str_ atmpted,r_sig_str_acc`	Volumen y eficacia de golpes significativos del rincón rojo.
`r_total_str_landed,r_total_str_ atmpted,r_total_str_acc`	Volumen y eficacia de golpes totales del rincón rojo.
`r_td_landed,r_td_atmpted,r_td_acc`	Derribos del rincón rojo: concretados, intentados y efectividad.
`r_head_landed,r_head_atmpted,r_ head_acc,r_body_landed,r_body_ atmpted,r_body_acc,r_leg_landed,r_ leg_atmpted,r_leg_acc`	Golpeo del rincón rojo por zona objetivo (cabeza, cuerpo, pierna).
`r_dist_landed,r_dist_atmpted,r_ dist_acc,r_clinch_landed,r_clinch_ atmpted,r_clinch_acc,r_ground_ landed,r_ground_atmpted,r_ground_ acc`	Golpeo del rincón rojo por distancia/fase (larga distancia, clinch, suelo).
`r_landed_head_per,r_landed_body_ per,r_landed_leg_per,r_landed_ dist_per,r_landed_clinch_per,r_ landed_ground_per`	Distribución porcentual del daño/impacto del rincón rojo por zona y situación.
`r_splm,r_str_acc,r_sapm,r_str_def, r_td_avg,r_td_avg_acc,r_td_def,r_ sub_avg`	Promedios de rendimiento histórico del rincón rojo (golpeo, defensa, lucha y sumisiones).
`b_name,b_id,b_nick_name,b_dob,b_ stance`	Identidad y perfil básico del peleador del rincón azul.

Columnas incluidas	Descripción
b_height,b_weight,b_reach	Características físicas del peleador del rincón azul.
b_wins,b_losses,b_draws	Historial acumulado de resultados del rincón azul.
b_kd,b_sub_att,b_ctrl	Métricas directas del combate para el rincón azul: knockdowns, intentos de sumisión y control posicional.
b_sig_str_landed,b_sig_str_atmpted,b_sig_str_acc	Volumen y eficacia de golpes significativos del rincón azul.
b_total_str_landed,b_total_str_atmpted,b_total_str_acc	Volumen y eficacia de golpes totales del rincón azul.
b_td_landed,b_td_atmpted,b_td_acc	Derribos del rincón azul: concretados, intentados y efectividad.
b_head_landed,b_head_atmpted,b_head_acc,b_body_landed,b_body_atmpted,b_body_acc,b_leg_landed,b_leg_atmpted,b_leg_acc	Golpeo del rincón azul por zona objetivo (cabeza, cuerpo, pierna).
b_dist_landed,b_dist_atmpted,b_dist_acc,b_clinch_landed,b_clinch_atmpted,b_clinch_acc,b_ground_landed,b_ground_atmpted,b_ground_acc	Golpeo del rincón azul por distancia/fase (larga distancia, clinch, suelo).
b_landed_head_per,b_landed_body_per,b_landed_leg_per,b_landed_dist_per,b_landed_clinch_per,b_landed_ground_per	Distribución porcentual del daño/impacto del rincón azul por zona y situación.
b_splm,b_str_acc,b_sapm,b_str_def,b_td_avg,b_td_avg_acc,b_td_def,b_sub_avg	Promedios de rendimiento histórico del rincón azul (golpeo, defensa, lucha y sumisiones).
winner,winner_id	Resultado observado del combate (ganador) y su identificador.

4. Criterio de depuración de datos (abierto)

La eliminación de datos se deja abierta en esta etapa, ya que todavía no se determinó con evidencia qué variables serán realmente útiles para responder las preguntas del trabajo.

Primero se realizará un análisis exploratorio integral de las 124 columnas y, a partir de ese análisis, se definirá si conviene descartar.

5. Información complementaria del dataset

El archivo `UFC.csv` reúne con detalle 124 atributos, y en los otros archivos adjuntos de la descarga se encuentran listados por separado luchadores, peleas y eventos, abriendo posibilidades de cruces en bases más segmentadas. La riqueza técnica del conjunto radica en la distinción estadística para cada rincón en el octágono, midiendo trabajo en cabeza, cuerpo, distancias y porcentajes de control. Se trata de un archivo real alimentado gradualmente.

Los datos fueron relevados haciendo un scraping del sitio http://ufcstats.com/statistics/

events/completed.