# Elección y Descripción del Conjunto de Datos, Grupo 1

Matías López, Isidro Silicaro Pera, Taciano Pacchialat

## 1. Introducción

En este trabajo se utilizará el conjunto de datos *UFC Datasets 1994-2025*, disponible en Kaggle bajo el nombre https://www.kaggle.com/datasets/neelagiriaditya/ufc-datasets-1994-2025.

El dataset fue seleccionado porque agrupa de manera detallada el historial de peleas de la compañía de artes marciales mixtas UFC (Ultimate Fighting Championship), sus atributos físicos, técnicas y resultados de los combates a lo largo de más de 30 años. Esta información presenta una oportunidad muy valiosa para realizar tareas de análisis de datos, estudiar las evoluciones de estilos de pelea, examinar estadísticas entre peleadores (esquinas roja y azul) y hasta para predecir el ganador de hipotéticos combates.

## 2. Origen y características generales

El conjunto de datos unificado `UFC.csv` disponible como parte de los datasets de UFC contiene **8.337 registros** y **124 columnas**. Reúne una vasta cantidad de atributos capturados a lo largo de décadas mostrando un detallado registro por cada pelea que ocurrió en diversas locaciones del mundo a partir de 1994 hasta inicios de 2025.

De manera general, el conjunto de datos clasifica su información en las siguientes partes:

- Variables de contexto de evento: nombre del evento, fecha, locación y división de peso (ej. Lightweight, Heavyweight).
- Variables del combate: tiempo total de combate, si es o no por el título, y método de finalización de la pelea (sumisión, nocaut, decisión, etc.).
- Variables específicas por rincón (Rojo `r_` y Azul `b_`): información que se recolecta del peleador antes y durante el combate, que abarca desde la edad, postura y dimensiones físicas, hasta métricas clave de desempeño en la pelea como precisión de los golpes, intentos de derribo (takedowns), control en el suelo, y otros tipos de agresiones.
- Variables de salida (target): la predicción o resultado de la pelea indicando quién fue el vencedor del enfrentamiento.

## 3. Descripción de las variables principales

Dado el gran número de dimensiones (124) que abarca cada combate, en la Tabla 1 se resumen algunos de los atributos más representativos incluidos en el archivo `UFC.csv`.

Cuadro 1: Descripción de variables clave del dataset UFC.

| Variable | Tipo | Descripción |
|---|---|---|
| `event_name` | Texto | Nombre representativo del evento de UFC. |
| `date` | Fecha | Fecha exacta en la que ocurrió el combate. |
| `location` | Texto | Ciudad y país, o estado donde se organizó la pelea. |
| `division` | Categórica | Categoría o división de peso de los combatientes. |
| `title_fight` | Binaria | Indica si en la contienda había algún título oficial en juego. |
| `method` | Categórica | Método por el cual se resolvió y dio por terminada la pelea. |
| `r_name/b_name` | Texto | Nombres de los respectivos peleadores de las esquinas Roja (R) y Azul (B). |
| `r_height/b_height` | Numérica | Altura de ambos peleadores en pulgadas. |
| `r_weight/b_weight` | Numérica | Peso declarado para la competición. |
| `r_reach/b_reach` | Numérica | Envergadura / alcance oficial de los brazos de ambos peleadores. |
| `r_stance/b_stance` | Categórica | Tipo de guardia adoptada (ej. *Orthodox*, *Southpaw*). |
| `..._sig_str_landed` | Numérica | Por ambos rincones, cuenta la cantidad de "strikes" o golpes significativos conectados en una pelea. |
| `..._total_str_acc` | Numérica | Por ambos rincones, evalúa el porcentaje de acierto de los golpes lanzados. |
| `..._td_landed/atmpt` | Numérica | Por ambos rincones, refleja la cantidad de derribos aterrizados v/s intentados. |
| `winner` | Texto | Determina el peleador vencedor del enfrentamiento en cuestión. |
| `winner_id` | Texto | Identificador único en el sistema para el vencedor de la pelea. |

## 4. Información complementaria del dataset

El archivo `UFC.csv` reúne con detalle 124 atributos, y en los otros archivos adjuntos de la descarga se encuentran listados por separado a cada luchador, pelea y eventos en general, abriendo posibilidades a cruzar la información en bases de datos más segmentadas. La riqueza técnica del conjunto radica en la gran distinción estadística para cada rincón en el octágono, midiendo el trabajo del luchador centrado en la cabeza, el cuerpo, las distancias y los porcentajes de control. Se trata de un archivo real alimentado gradualmente que resulta propicio para aplicar tanto análisis exploratorio exhaustivo como para modelos de predicción y *machine learning*.