Elección y Descripción del Conjunto de Datos, Grupo 1

Matías López, Isidro Silicaro Pera, Taciano Pacchialat

1. Introducción

En este trabajo se utilizará el conjunto de datos *Sleep Health & Daily Performance Dataset*, disponible en Kaggle bajo el nombre https://www.kaggle.com/datasets/mohankrishnathalla/sleep-health-and-daily-performance-dataset.

El dataset fue seleccionado porque reúne hábitos de vida e indicadores fisiológicos vinculados al sueño. Esa combinación lo vuelve apropiado para tareas de análisis de datos, además de permitir estudiar relaciones entre estilo de vida, descanso y rendimiento cognitivo.

2. Origen y características generales

La versión publicada en Kaggle contiene **100.000 registros** y **32 columnas**. Los datos son sintéticos, pero fueron generados con relaciones estadísticas coherentes con estudios de salud del sueño y con perfiles ocupacionales diferenciados. No se reportan valores faltantes.

De manera general, el conjunto de datos incluye:

- Variables demográficas: edad, género, ocupación, país y cronotipo (inclinación natural del cuerpo para dormirse y despertarse a una cierta hora);
- Variables fisiológicas: duración del sueño, calidad del sueño, porcentaje de REM, porcentaje de sueño profundo, latencia de sueño, frecuencia en la que se despertó durante el sueño y frecuencia cardíaca en reposo;
- Variables de hábitos: consumo de cafeína y alcohol antes de dormir, sueño asistido, tiempo frente a pantallas, ejercicio diario, pasos diarios y si la persona realiza turnos rotativos en el trabajo;
- Variables contextuales: temperatura de la habitación, estación del año y tipo de día (soleado, nublado, etc.);
- Variables de salida: desempeño cognitivo, riesgo de trastorno del sueño y sensación subjetiva de haber descansado.

3. Descripción de las variables

En la Tabla 1 se resume el significado de cada atributo incluido en el archivo `sleep_health_dataset.csv`.

Cuadro 1: Descripción de las variables del dataset.

Variable	Tipo	Descripción
person_id	Entero	Identificador único de cada registro.
age	Entero	Edad de la persona, en años.
gender	Categórica	Género reportado.
occupation	Categórica	Ocupación principal de la persona.
bmi	Numérica	Índice de masa corporal.
country	Categórica	País de residencia.
sleep_duration_hrs	Numérica	Duración del sueño nocturno en horas.
sleep_quality_score	Numérica	Puntaje de calidad del sueño.
rem_percentage	Numérica	Porcentaje de sueño REM.
deep_sleep_percentage	Numérica	Porcentaje de sueño profundo.
sleep_latency_mins	Entero	Minutos necesarios para conciliar el sueño.
wake_episodes_per_night	Entero	Cantidad de despertares durante la noche.
caffeine_mg_before_bed	Entero	Miligramos de cafeína consumidos antes de acostarse.
alcohol_units_before_bed	Numérica	Unidades de alcohol consumidas antes de acostarse.
screen_time_before_bed_mins	Entero	Minutos de uso de pantallas antes de dormir.
exercise_day	Binaria	Indica si realizó ejercicio ese día.
steps_that_day	Entero	Cantidad de pasos realizados durante el día.
nap_duration_mins	Entero	Duración de la siesta, en minutos.
stress_score	Numérica	Puntaje de estrés autoinformado.
work_hours_that_day	Numérica	Cantidad de horas trabajadas ese día.
chronotype	Categórica	Cronotipo o preferencia horaria (por ejemplo, morning, neutral, evening).
mental_health_condition	Categórica	Condición de salud mental reportada.
heart_rate_resting_bpm	Entero	Frecuencia cardíaca en reposo, en latidos por minuto.
sleep_aid_used	Binaria	Indica si se utilizó ayuda para dormir.
shift_work	Binaria	Indica si la persona realiza trabajo por turnos.
room_temperature_celsius	Numérica	Temperatura de la habitación en grados Celsius.
weekend_sleep_diff_hrs	Numérica	Diferencia de horas de sueño entre fin de semana y días de semana.
season	Categórica	Estación del año correspondiente al registro.
day_type	Categórica	Tipo de día: día hábil o fin de semana.
cognitive_performance_score	Numérica	Puntaje de desempeño cognitivo asociado al día siguiente.
sleep_disorder_risk	Categórica	Nivel de riesgo de trastorno del sueño.
felt_rested	Binaria	Variable objetivo que indica si la persona se sintió descansada.

4. Información complementaria del dataset

El dataset contiene 100.000 ejemplos y 32 atributos. Incluye atributos numéricos (`sleep_duration_hrs`, `stress_score`), categóricos (`occupation`, `chronotype`, `season`) y binarios (`exercise_day`, `felt_rested`). Según la descripción oficial en Kaggle, no se trata de una encuesta ni de scraping directo, sino de un dataset sintético. Los registros fueron generados para imitar patrones realistas de sueño y desempeño diario, preservando relaciones estadísticas plausibles entre variables de hábitos, salud y rendimiento, sin exponer datos personales reales.El dataset no presenta valores faltantes. La nomenclatura de variables ya se encuentra unificada en formato `snake_case`, lo que simplifica el preprocesamiento.